Pertahanan Adaptif pada Konsensus *Proof-of-Stake* Menggunakan *Multi-Agent Reinforcement Learning*

Proposal Tugas Akhir

Oleh

Samuel Chris Michael Bagasta Simanjuntak
18223011



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

2026

LEMBAR PENGESAHAN

Pertahanan Adaptif pada Konsensus *Proof-of-Stake* Menggunakan *Multi-Agent Reinforcement Learning*

Proposal Tugas Akhir

Oleh

Samuel Chris Michael Bagasta Simanjuntak
18223011

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 29 Oktober 2026

Pembimbing

Dr. Ir. Dimitri Mahayana, M.Eng.
NIP. 196808091991021001

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Proposal Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan Proposal Tugas Akhir.
3. Isi proposal ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa dokumen laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 29 Oktober 2026

Samuel Chris Michael Bagasta Simanjuntak
NIM: 18223011

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan Proposal Tugas Akhir ini, saya telah menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu. Berikut adalah rincian penggunaan AI dalam penulisan tesis ini.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II dan Subbab III.2 hal. 34
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	…	…	…
5	Menjelaskan definisi, konsep, gambar, tabel, atau topik tertentu	…	…	…
6	Penyusunan kode program	…	…	…
7	Penyusunan formula atau perhitungan matematis	…	…	…
8	Analisis data	…	…	…
9	Penyusunan kesimpulan atau rekomendasi	…	…	…
10	Lainnya (jelaskan)	…	…	…

Bandung, 29 Oktober 2026

John Doe
NIM: 18299000

DAFTAR ISI

LEMBAR PENGESAHAN iii
PERNYATAAN ORISINALITAS v
PERNYATAAN PENGGUNAAN AI vii
DAFTAR ISI ix
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR PERSAMAAN xv
DAFTAR ALGORITMA xvii
DAFTAR KODE PROGRAM xix
DAFTAR SINGKATAN xxi
DAFTAR SIMBOL xxiii

BAB I PENDAHULUAN 1
I.1 Latar Belakang 1
I.2 Rumusan Masalah 3
I.3 Tujuan 4
I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah 5
I.5 Hipotesis Tugas Akhir 6
I.6 Metodologi 7
I.7 Sistematika Penulisan 8

BAB II STUDI LITERATUR 11
II.1 Metode Penelusuran Literatur 11
II.2 Konsensus *Proof-of-Stake* Gasper 12
II.2.1 Struktur Waktu dan Pemilihan *Proposer* 12
II.2.2 Pemilihan Rantai Utama dan Finalisasi 12
II.2.3 Insentif dan Parameter Finalitas 12
II.3 Serangan Strategis dan Mitigasinya 13
II.3.1 Penahanan dan Pelepasan Blok 13
II.3.2 Serangan *Balancing* dan *Bouncing* 14
II.3.3 *Censorship* terhadap *Attestation* 14
II.3.4 Ambang Kekuatan Penyerang 14
II.3.5 Mitigasi Saat Ini dan Dilemanya 15
II.4 Pendekatan Analisis Keamanan Konsensus 15
II.5 Dasar Teori *Reinforcement Learning* 16
II.5.1 *Markov Decision Process* dan Versi Terbatasnya 16
II.5.2 *Markov Game* untuk Interaksi Penyerang dan Pertahanan . 16
II.5.3 *Deep Q-Network* dan Variannya 17
II.5.4 *Self-Play* dan Kumpulan Lawan 19
II.5.5 Metrik Ketangguhan 19
II.5.6 Rancangan Awal Ruang *State*, *Action*, dan *Reward* 20
II.5.7 Batas Perubahan Parameter Konsensus 21
II.6 Penerapan AI pada Konsensus *Blockchain* 22
II.7 Pertahanan Adaptif Berbasis *Reinforcement Learning* 23

II.8 Penelitian Terkait dan Posisi Tugas Akhir 24
II.8.1 Studi Primer Terdekat 24
II.8.2 Perbandingan Penelitian Terkait 24
II.8.3 Celah Penelitian dalam Cakupan Penelusuran 24

BAB III ANALISIS MASALAH 27
III.1 Analisis Kondisi Saat Ini 27
III.2 Analisis Kebutuhan 29
III.2.1 Identifikasi Masalah Pengguna 29
III.2.2 Kebutuhan Fungsional 30
III.2.3 Kebutuhan Nonfungsional 30
III.3 Analisis Pemilihan Solusi 30
III.3.1 Alternatif Solusi 30
III.3.2 Analisis Penentuan Solusi 33

BAB IV DESAIN KONSEP SOLUSI 37

BAB V RENCANA SELANJUTNYA 39

DAFTAR PUSTAKA 41

Lampiran A *SOURCE CODE* 43
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik . . . 43
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak 44

DAFTAR GAMBAR

III.1 Model konseptual sistem pertahanan Gasper saat ini. Label M1 sampai M4 menandai letak masalah pada Tabel III.1 28

DAFTAR TABEL

I.1 Ruang lingkup penelitian pada setiap komponen arena 6
I.2 Keterkaitan premis literatur dengan hipotesis tugas akhir 7
I.3 Keterkaitan tahapan metodologi dengan rumusan masalah 8

II.1 Rancangan awal ruang *state*, *action*, dan *reward* kedua agen 20
II.2 Rancangan awal parameter yang dapat disetel agen pertahanan beserta batas perubahannya 22
II.3 Perbandingan penelitian terkait dan bagian yang diadopsi tugas akhir ini 25

III.1 Masalah pada sistem pertahanan Gasper saat ini 29
III.2 Masalah dan kebutuhan setiap pemangku kepentingan 30
III.3 Kebutuhan fungsional arena penyerang dan pertahanan 31
III.4 Kebutuhan nonfungsional beserta kriteria terukurnya 32
III.5 Ringkasan alternatif solusi beserta bukti dan kelemahannya 34
III.6 Penilaian alternatif solusi terhadap kriteria pemilihan 34
III.7 Perbandingan keluarga algoritma untuk kedua agen 35
III.8 Keterlacakan masalah, kebutuhan, komponen solusi, dan pertanyaan penelitian 36

DAFTAR PERSAMAAN

II.1 Syarat *checkpoint* menjadi *justified* 12
II.2 *Reward* dasar validator 13
II.3 Fungsi tujuan *Constrained Markov Decision Process* 16
II.4 *Markov game* dua agen dengan batasan 17
II.5 Target pembaruan *Double* DQN 18
II.6 Penggabungan nilai pada *dueling network* 18
II.7 Pengambilan lawan dari kumpulan penyerang historis 19
II.8 Profit relatif penyerang 19
II.9 *Exploitability* pertahanan 20
II.10 Rancangan fungsi *reward* agen pertahanan 21
II.11 Batasan perubahan parameter konsensus 21

DAFTAR ALGORITMA

DAFTAR *LISTING*

A.1 Binary search code 43

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	*Artificial Intelligence*	
CMDP	*Constrained Markov Decision Process*	
CPU	*Central Processing Unit*	
DDPG	*Deep Deterministic Policy Gradient*	
DDQN	*Double Deep Q-Network*	
DQN	*Deep Q-Network*	
DRL	*Deep Reinforcement Learning*	
ETH	*Ether*, mata uang kripto jaringan *Ethereum*	
EWMA	*Exponentially Weighted Moving Average*	
FFG	*Friendly Finality Gadget*	
GAN	*Generative Adversarial Network*	
GPU	*Graphics Processing Unit*	
IIoT	*Industrial Internet of Things*	
KF	Kebutuhan Fungsional	
KNF	Kebutuhan Nonfungsional	
LMD-GHOST	*Latest Message Driven Greedy Heaviest Observed Sub-Tree*	
MARL	*Multi-Agent Reinforcement Learning*	
MDP	*Markov Decision Process*	
MEV	*Maximal Extractable Value*	
ML	*Machine Learning*	
PBFT	*Practical Byzantine Fault Tolerance*	
PER	*Prioritized Experience Replay*	
PID	*Proportional-Integral-Derivative*	
PoS	*Proof-of-Stake*	
PoW	*Proof-of-Work*	
PPO	*Proximal Policy Optimization*	
RL	*Reinforcement Learning*	
ROI	*Return on Investment*	
RQ	*Research Question*	
SLR	*Systematic Literature Review*	

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
$stake_i$	Saldo efektif (*stake*) validator ke-i	
V	Himpunan seluruh validator aktif	
V_c	Himpunan validator yang memilih *checkpoint* c	
$\mathcal{S}$	Ruang *state*	
$\mathcal{A}$	Ruang aksi	
$\mathcal{A}^k$	Ruang aksi agen ke-k	
P	Peluang transisi antar-*state*	
R, R^k	Fungsi *reward* (agen ke-k)	
r_t	*Reward* pada langkah waktu t	
γ	Faktor diskon	
π	Kebijakan (*policy*) agen	
c_i	Biaya kendala ke-i pada CMDP	
d_i	Batas maksimum biaya kendala ke-i	
$\mathcal{G}$	*Markov game*	
$\mathcal{N}$	Himpunan agen	
θ	Parameter jaringan kebijakan	
$r_t(\theta)$	Rasio peluang aksi kebijakan baru terhadap kebijakan lama	
$\hat{A}_t$	Estimasi *advantage* pada langkah t	
ϵ	Batas *clipping* pada PPO	
H_0, H_1	Hipotesis nol dan hipotesis alternatif	
$\mathbb{E}$	Nilai harapan (ekspektasi)	
$\sum$	Operator penjumlahan	
$\propto$	Sebanding dengan	

BAB I

PENDAHULUAN

I.1 Latar Belakang

Ethereum menjalankan konsensus *Proof-of-Stake* (PoS) melalui protokol Gasper. Waktu dibagi menjadi *slot* berdurasi 12 detik, setiap 32 *slot* membentuk satu *epoch*, dan blok pertama setiap *epoch* disebut *checkpoint*. Sebuah *checkpoint* menjadi *justified* jika didukung validator yang memegang minimal dua pertiga total *stake*, lalu menjadi *finalized* jika *checkpoint* berikutnya juga *justified* (Laneve & Veschetti, 2025). Keamanan protokol ini bertumpu pada insentif. Validator yang memberi suara sejalan dengan mayoritas menerima *reward*. Suara yang melewati batas inklusi 32 *slot* ditolak dan dikenai penalti. Validator yang mengusulkan dua blok pada *slot* yang sama atau memberi suara ganda dikenai *slashing*, yaitu kehilangan 1/32 saldo dan dikeluarkan dari jaringan selama 36 hari (Laneve & Veschetti, 2025).

Masalahnya, nilai parameter tersebut tetap, sedangkan penyerang terus menyesuaikan strategi. Laneve dan Veschetti (2025) menunjukkan tiga serangan yang efektif terhadap Gasper. Pada serangan *balancing*, 4 dari 13 validator, atau kurang dari sepertiga, cukup untuk mencegah finalisasi dengan memecah suara validator jujur ke dua cabang. Serangan *bouncing* membuat justifikasi berpindah antarcabang sehingga finalisasi lumpuh. Serangan waktu (*time attack*) memanfaatkan *inactivity leak* untuk menggerus *stake* validator jujur yang tertunda sampai penyerang menguasai dua pertiga suara. Respons terhadap serangan tersebut selalu berupa tambalan manual yang khusus untuk satu jenis serangan. Serangan *balancing* diredam dengan *proposer boost* berbobot tetap 40%, sedangkan tambalan *bouncing* berupa batas *slot* pengiriman suara pernah diterapkan lalu dihapus (Laneve & Veschetti, 2025). Pola ini reaktif. Parameter ditetapkan sekali, lalu diubah setelah serangan baru ditemukan.

Persoalan ini mendesak karena menyangkut dua sifat utama jaringan, yaitu *safety* (blok yang sudah final tidak boleh dibatalkan) dan *liveness* (jaringan terus memfinalisasi blok baru). Margin *liveness* Gasper ternyata tipis. Tanpa serangan pun, latensi

rata-rata 38 detik membuat *checkpoint* tidak pasti *justified* dalam sembilan *epoch*, dan peluang finalisasi baru mendekati 0,99 setelah 12 *epoch* (Laneve & Veschetti, 2025). Penyerang yang menunda atau memecah suara dapat mendorong jaringan melewati margin tersebut. Bukti dari *blockchain* lain menunjukkan risiko pertahanan statis secara langsung. Pada *Proof-of-Work* (PoW), pertahanan berambang tetap awalnya membuat serangan merugi hingga -95%, tetapi penyerang adaptif menembusnya setelah sekitar 20 hari sehingga profit rata-rata 30 hari kembali positif ($+65\%$) (Skowroński, 2026). Artinya, parameter yang dinilai aman hari ini belum tentu aman setelah penyerang beradaptasi. Survei Rizal dan Kim (2025) juga mencatat ketahanan terhadap serangan canggih sebagai celah yang masih terbuka pada konsensus *blockchain*.

Literatur menawarkan empat pendekatan. Pertama, analisis formal memodelkan Gasper sebagai proses stokastik dan mengujinya dengan *probabilistic model checker* PRISM+ pada berbagai latensi, jumlah validator, dan skenario serangan (Laneve & Veschetti, 2025). Kedua, *machine learning* (ML) dipakai untuk prediksi, deteksi anomali, dan konsensus adaptif (Rizal & Kim, 2025). Ketiga, agen *Deep Reinforcement Learning* (DRL) menyetel parameter deteksi secara dinamis dalam batas aman dan menjaga profit penyerang tetap negatif (-42%) ketika pertahanan statis sudah ditembus (Skowroński, 2026). Keempat, pelatihan ko-evolusioner melatih agen pertahanan bersama agen penyerang yang ikut belajar dan kumpulan penyerang historis. Hasilnya, tingkat mitigasi hanya turun 4,9% dari penyerang acak hingga penyerang yang dilatih khusus untuk melawannya (Wushishi dkk. 2026).

Keempat pendekatan tersebut masih menyisakan celah. Analisis formal memakai penyerang dengan perilaku tetap (*scripted*) dan parameter yang diubah manual, sehingga analisis harus diulang untuk setiap varian serangan (Laneve & Veschetti, 2025). Pemanfaatan ML pada konsensus masih didominasi prediksi dan deteksi pasif (Rizal & Kim, 2025). Pertahanan DRL sudah adaptif, tetapi diterapkan pada PoW, hanya menyetel ambang deteksi, dan menghadapi penyerang yang beradaptasi secara heuristik, bukan penyerang yang belajar (Skowroński, 2026). Pelatihan ko-evolusioner sudah dua sisi, tetapi diterapkan pada *Industrial Internet of Things* (IIoT), bukan pada konsensus *blockchain* (Wushishi dkk. 2026). Menariknya, keempat studi menunjuk arah lanjutan yang sama. Laneve dan Veschetti (2025) menyebut perlunya menguji Gasper terhadap strategi penyerang yang terus berkembang. Skowroński (2026) mengusulkan pelatihan *self-play* dengan *Multi-Agent Reinforcement Learning* (MARL) serta perluasan ke konsensus PoS. Wushishi dkk. (2026) mengarahkan riset lanjutan ke pertahanan ko-evolusioner multi-agen. Rizal

dan Kim (2025) menempatkan *blockchain* yang menyetel parameternya sendiri sebagai arah riset ke depan. Namun, belum ada yang menggabungkan arah tersebut pada Gasper. Tugas akhir ini mengisi celah itu dengan membangun arena penyerang dan pertahanan pada konsensus Gasper. Di dalam arena ini, agen pertahanan belajar menyetel parameter insentif secara adaptif melawan agen penyerang yang juga belajar.

I.2 Rumusan Masalah

Pokok persoalan tugas akhir ini adalah ketahanan Gasper selama ini dinilai terhadap pola serangan yang tetap, sementara parameter pertahanannya dibiarkan statis atau ditambal manual setelah serangan ditemukan (Laneve & Veschetti, 2025). Akibatnya, kesimpulan bahwa suatu nilai parameter sudah aman hanya berlaku untuk pola serangan yang diuji. Jika penyerang diberi kesempatan beradaptasi, tidak ada jaminan nilai yang sama tetap efektif. Gejala ini sudah teramati pada PoW ketika pertahanan statis ditembus penyerang adaptif dalam sekitar 20 hari (Skowroński, 2026). Evaluasi terhadap penyerang tetap juga cenderung melebihkan ketangguhan. Pertahanan yang dilatih tanpa penyerang ko-evolusioner tampak baik pada pengujian biasa, tetapi tingkat mitigasinya turun dari 0,778 menjadi 0,681 ketika menghadapi penyerang adaptif (Wushishi dkk. 2026).

Masalah ini penting diselesaikan karena salah menilai ketahanan protokol berujung pada kerugian nyata. Pelanggaran *safety* dapat membatalkan transaksi yang sudah final. Gangguan *liveness* menahan transaksi baru dan menggerus *stake* validator jujur melalui penalti ketidakaktifan (Laneve & Veschetti, 2025).

Sebagai solusi, tugas akhir ini memodelkan interaksi penyerang dan pertahanan pada Gasper sebagai permainan dua agen yang dilatih secara ko-evolusioner dengan MARL. Kedua pihak sama-sama diberi kesempatan beradaptasi sebelum ketahanan kebijakan pertahanan dinilai. Dengan demikian, evaluasi bergeser dari pengujian terhadap penyerang tetap menjadi pengujian terhadap penyerang yang belajar.

Rumusan masalah tersebut dijabarkan menjadi tiga pertanyaan penelitian (*Research Question*/RQ) berikut.

- **RQ1:** Sejauh mana simulator Gasper level *slot* dan *epoch* beserta formulasi *Markov game* dua agen mampu mereproduksi perilaku Gasper dalam kondisi normal dan merepresentasikan adaptasi penyerang dan pertahanan tanpa melanggar invarian protokol?
- **RQ2:** Apakah kebijakan pertahanan hasil pelatihan ko-evolusioner menghasilkan profit relatif penyerang serta tingkat pelanggaran *safety* dan *liveness*

yang lebih rendah dibanding parameter statis, ketika keduanya diuji melawan penyerang adaptif yang tidak pernah dilihat selama pelatihan?

- **RQ3:** Pola strategi serangan apa yang ditemukan agen penyerang, dan berapa biaya pertahanan berupa *reward* validator jujur yang hilang untuk menekan strategi tersebut?

I.3 Tujuan

Berdasarkan rumusan masalah di atas, tugas akhir ini bertujuan untuk:

1. Membangun simulator Gasper level *slot* dan *epoch* yang terverifikasi terhadap model acuan dan terkalibrasi dengan data *on-chain Ethereum*, lalu merumuskan interaksi penyerang dan pertahanan di dalamnya sebagai *Markov game* (RQ1);
2. Melatih agen pertahanan berbasis *Double Deep Q-Network* (DDQN) secara ko-evolusioner melawan agen penyerang dan kumpulan penyerang historis untuk menyetel *reward*, *slashing*, batas inklusi *attestation*, dan laju *inactivity leak*, lalu membandingkan ketahanannya dengan parameter statis (RQ2);
3. Menganalisis strategi serangan yang muncul serta mengukur *trade-off* antara penurunan profit penyerang dan biaya pertahanan bagi validator jujur (RQ3).

Tugas akhir ini dinyatakan berhasil jika memenuhi dua kriteria berikut.

1. **Simulator valid.** Validasi dilakukan dalam dua tahap. Tahap verifikasi memakai konfigurasi yang sama dengan Laneve dan Veschetti (2025), yaitu 13 validator dan latensi rata-rata 12,6 detik. Pada tahap ini, simulator harus mereproduksi peluang justifikasi dalam 64 *slot* (0,552) dan peluang finalisasi dalam 96 *slot* (mendekati 1) dengan selisih maksimal 0,05. Simulator juga harus mereproduksi gagalnya finalisasi akibat serangan *balancing* 4 dari 13 validator dan pulihnya finalisasi dalam 3 *epoch* setelah *proposer boost* 40% diterapkan. Tahap kalibrasi memakai data *on-chain*. Distribusi rasio *slot* kosong, tingkat partisipasi *attestation*, dan rasio blok yatim pada simulator tidak boleh berbeda signifikan dari data nyata menurut uji Kolmogorov-Smirnov ($p > 0{,}05$), mengikuti cara validasi simulator pada Skowroński (2026). Kriteria ini sekaligus menjawab keterbatasan Laneve dan Veschetti (2025) yang tidak menemukan acuan validasi dan hanya membandingkan modelnya dengan protokol pendahulu.
2. **Pertahanan adaptif lebih tangguh.** Ketika diuji melawan penyerang yang tidak pernah dilihat selama pelatihan, H_0 pada Subbab I.5 ditolak untuk profit relatif penyerang atau tingkat pelanggaran *safety* dan *liveness*, tanpa satu pun pelanggaran invarian protokol. Profit relatif dihitung terhadap pendapatan

penyerang jika ia bertindak jujur, mengikuti definisi Skowroński (2026).

I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah

Agar tugas akhir ini dapat diselesaikan dalam dua semester, ditetapkan batasan berikut.

1. **Protokol.** Protokol yang dimodelkan hanya Gasper (LMD-GHOST dan Casper FFG). Protokol PoS lain seperti *Tendermint* dan *Ouroboros* tidak dibahas karena aturan pemilihan rantai dan finalitasnya berbeda (Laneve & Veschetti, 2025).
2. **Serangan.** Penyerang adalah satu koalisi dengan *stake* di bawah sepertiga. Serangan dibatasi pada tiga kategori, yaitu (a) penahanan dan pelepasan blok strategis yang sejenis *selfish mining* pada PoW (Skowroński, 2026), (b) *balancing* melalui penahanan dan pelepasan suara, dan (c) *censorship* terhadap *attestation* oleh *proposer* penyerang. *Maximal Extractable Value* (MEV) tidak dimodelkan karena membutuhkan isi transaksi, sedangkan simulator memperlakukan blok sebagai kotak hitam. *Long-range attack* tidak dimodelkan karena membutuhkan validator yang keluar masuk jaringan, aspek yang juga belum dimodelkan Laneve dan Veschetti (2025). Serangan *bouncing* tidak diskenariokan khusus karena sulit direproduksi pada Gasper saat ini, tetapi tetap dapat muncul dari hasil belajar agen penyerang. *Time attack* tidak dimodelkan karena bergantung pada manipulasi sinkronisasi jam di luar model level *slot*.
3. **Aksi pertahanan.** Agen pertahanan hanya menyetel empat parameter insentif, yaitu pengali *reward* dasar, pengali penalti *slashing*, batas inklusi *attestation*, dan pengali laju *inactivity leak*. Aturan pemilihan rantai, termasuk *proposer boost* 40%, serta ambang dua pertiga dikunci.
4. **Simulator.** Simulator berupa model ringan level *slot* dan *epoch*, bukan *node Ethereum* lengkap, dan tidak dijalankan di *testnet* maupun *mainnet*. Penyederhanaan berupa blok sebagai kotak hitam dan tanpa pembagian komite telah terbukti memadai untuk menganalisis justifikasi dan finalisasi Gasper (Laneve & Veschetti, 2025).
5. **Skala jaringan.** Verifikasi memakai 13 validator agar sebanding dengan Laneve dan Veschetti (2025), yang melaporkan hasil sudah stabil pada 10 sampai 13 validator. Eksperimen utama memakai 64 sampai 256 validator, mengikuti variasi skala pada Skowroński (2026). Uji skalabilitas dilakukan hingga 1.000 validator, mengikuti uji skala Wushishi dkk. (2026).
6. **Data dan sumber daya.** Kalibrasi memakai data *on-chain* publik (*BigQuery* dan *beaconcha.in*) serta spesifikasi resmi *consensus-specs*, yang diasumsikan

cukup mewakili perilaku jaringan. Komputasi dibatasi pada CPU *multi-core* dan GPU kelas menengah. Batas ini realistis karena satu sesi pelatihan DRL 200 ribu langkah pada Skowroński (2026) selesai sekitar 8 jam pada satu GPU.

Ringkasan ruang lingkup disajikan pada Tabel I.1.

Tabel I.1 Ruang lingkup penelitian pada setiap komponen arena

Komponen	**Termasuk ruang lingkup**	**Di luar ruang lingkup**
Protokol	Gasper (LMD-GHOST dan Casper FFG)	*Tendermint*, *Ouroboros*, PoS lain
Serangan	Penahanan dan pelepasan blok, *balancing*, *censorship attestation*	MEV, *long-range*, *time attack*, *bouncing* terskenario
Aksi pertahanan	*Reward*, *slashing*, batas inklusi, *inactivity leak*	Aturan pemilihan rantai, ambang dua pertiga
Simulator	Model ringan level *slot* dan *epoch*	*Full node*, *testnet*, *mainnet*
Skala	13 (verifikasi), 64 sampai 256 (utama), hingga 1.000 (uji skala)	Skala *mainnet*
Data	*BigQuery*, *beaconcha.in*, *consensus-specs*	Data non-publik

I.5 Hipotesis Tugas Akhir

Hipotesis disusun dari empat premis. Pertama, Gasper dengan parameter tetap dapat digagalkan finalisasinya oleh penyerang berporsi kecil, dan mitigasinya masih manual (Laneve & Veschetti, 2025). Kedua, pada domain *blockchain*, pertahanan DRL yang menyetel parameternya sendiri menjaga serangan tetap merugi (-42%), sedangkan pertahanan statis akhirnya ditembus ($+65\%$), tanpa satu pun pelanggaran batas keselamatan (Skowroński, 2026). Ketiga, pertahanan yang dilatih secara ko-evolusioner lebih tangguh terhadap penyerang adaptif daripada pertahanan yang dilatih melawan penyerang tetap, dengan tingkat mitigasi 0,803 berbanding 0,681 (Wushishi dkk. 2026). Keempat, penyetelan parameter konsensus terhadap kondisi jaringan layak dilakukan, tetapi berisiko memicu sentralisasi dan sulit diaudit jika tidak dibatasi (Rizal & Kim, 2025).

Misalkan μ_m^{MARL} dan μ_m^{statis} adalah rata-rata metrik keamanan m ketika pertahanan MARL dan pertahanan statis diuji melawan populasi penyerang adaptif yang sama. Metrik m adalah profit relatif penyerang dan tingkat pelanggaran *safety* serta *liveness*. Untuk setiap metrik, hipotesisnya adalah sebagai berikut.

- H_0: $\mu_m^{\text{MARL}} = \mu_m^{\text{statis}}$. Tidak ada perbedaan signifikan antara pertahanan MARL dan pertahanan statis.
- H_1: $\mu_m^{\text{MARL}} < \mu_m^{\text{statis}}$. Pertahanan MARL menghasilkan nilai metrik yang lebih rendah secara signifikan.

Penurunan tersebut diperkirakan disertai kenaikan biaya pertahanan berupa berku-

rangnya *reward* validator jujur. Biaya ini tidak dihipotesiskan, tetapi dianalisis sebagai *trade-off* pada RQ3. Keterkaitan premis dan hipotesis dirangkum pada Tabel I.2.

Tabel I.2 Keterkaitan premis literatur dengan hipotesis tugas akhir

Premis	**Temuan literatur**	**Kaitan dengan hipotesis**
Premis 1	Laneve & Veschetti (2025): Gasper berparameter tetap rentan terhadap serangan finalisasi dan mitigasinya manual	Kondisi awal yang diwakili pertahanan statis pada H_0
Premis 2	Skowroński (2026): pertahanan DRL adaptif mengalahkan pertahanan statis pada *blockchain* tanpa melanggar batas	Bukti arah H_1 pada domain *blockchain*
Premis 3	Wushishi dkk. (2026): pertahanan koevolusioner lebih tangguh terhadap penyerang adaptif	Bukti arah H_1 untuk pelatihan dua sisi
Premis 4	Rizal & Kim (2025): konsensus adaptif layak, tetapi perlu dibatasi agar tidak sentralistis	Dasar batas perubahan parameter saat menguji H_1

I.6 Metodologi

Tugas akhir ini menggunakan pendekatan eksperimen simulasi kuantitatif dengan tahapan berikut.

1. **Investigasi dan studi literatur.** Menelusuri kondisi keamanan konsensus PoS dan melakukan *systematic literature review* (SLR) di Scopus dengan *query* `TITLE-ABS-KEY(("proof of stake" OR blockchain OR consensus) AND "reinforcement learning" AND (attack OR defense OR security OR "selfish mining"))`. Hasilnya disajikan pada Bab II.
2. **Analisis kebutuhan dan pemilihan solusi.** Menurunkan masalah, kebutuhan fungsional, dan kebutuhan nonfungsional dari studi kasus dokumen terhadap keempat studi utama, lalu membandingkan alternatif solusi dengan kriteria yang terukur. Hasilnya disajikan pada Bab III.
3. **Perancangan simulator dan formulasi permainan.** Merancang arsitektur secara bertahap dari konteks sistem ke komponen (model C4) dengan diagram UML. Struktur modul simulator mengacu pada Laneve dan Veschetti (2025). Ruang *state*, *action*, dan *reward* kedua agen dirumuskan sebagai *Markov game* untuk menjawab RQ1.
4. **Implementasi dan validasi simulator.** Mengimplementasikan simulator dengan Python dan antarmuka multi-agen PettingZoo, lalu memvalidasinya dengan kriteria pertama pada Subbab I.3. Tahap berikutnya hanya dilanjutkan jika simulator lolos validasi.
5. **Pembanding.** Menyiapkan tiga pembanding, yaitu parameter statis, pengendali adaptif berbasis aturan, dan agen DRL satu sisi yang dilatih melawan penyerang tetap, mengikuti rancangan pembanding Skowroński (2026) dan

Wushishi dkk. (2026).

6. **Pelatihan ko-evolusioner.** Melatih agen pertahanan DDQN dengan *dueling network* dan *action masking* (Skowroński, 2026) melawan agen penyerang yang ikut belajar dan kumpulan 10 kebijakan penyerang historis (Wushishi dkk. 2026). Implementasi memakai PyTorch.
7. **Eksperimen dan evaluasi.** Menguji semua pertahanan melawan tiga rezim penyerang, yaitu penyerang terskenario, penyerang yang terus belajar selama pengujian, dan penyerang yang dilatih khusus melawan tiap pertahanan (Wushishi dkk. 2026). Evaluasi diulang 30 kali dengan *seed* berbeda (Skowroński, 2026). Signifikansi diuji dengan uji Wilcoxon *signed-rank* satu sisi dengan koreksi Bonferroni, dan besar efek dilaporkan dengan Cohen's d (Wushishi dkk. 2026).
8. **Analisis dan kesimpulan.** Menganalisis pola strategi kedua agen, mengaitkannya dengan RQ dan hipotesis, lalu menyusun kesimpulan dan saran.

Keterkaitan tahapan dengan rumusan masalah dirangkum pada Tabel I.3.

Tabel I.3 Keterkaitan tahapan metodologi dengan rumusan masalah

No.	Tahapan	Menjawab	Keluaran utama
1	Investigasi dan studi literatur	Latar belakang	Peta literatur dan celah (Bab II)
2	Analisis kebutuhan dan pemilihan solusi	Latar belakang	Kebutuhan dan solusi terpilih (Bab III)
3	Perancangan simulator dan permainan	RQ1	Arsitektur simulator dan *Markov game* (Bab IV)
4	Implementasi dan validasi simulator	RQ1, kriteria 1	Simulator tervalidasi
5	Pembanding	Konteks H_0	Pertahanan statis, berbasis aturan, dan DRL satu sisi
6	Pelatihan ko-evolusioner	RQ2	Kebijakan pertahanan adaptif
7	Eksperimen dan evaluasi	RQ2, RQ3, kriteria 2	Hasil uji H_0 dan H_1, metrik keamanan dan biaya
8	Analisis dan kesimpulan	Seluruh RQ	Simpulan dan saran

I.7 Sistematika Penulisan

Proposal ini disusun sebagai berikut.

1. **Bab I Pendahuluan** berisi latar belakang, rumusan masalah, tujuan, ruang lingkup, hipotesis, metodologi, dan sistematika penulisan.
2. **Bab II Studi Literatur** berisi cara kerja Gasper, serangan strategis dan mitigasinya, teori *reinforcement learning* untuk permainan dua agen, penelitian terkait, dan celah penelitian.
3. **Bab III Analisis Masalah** berisi model konseptual kondisi saat ini, analisis kebutuhan fungsional dan nonfungsional, serta analisis alternatif dan penen-

tuan solusi.

4. **Bab IV Desain Konsep Solusi** berisi model konseptual arena penyerang dan pertahanan beserta perbandingannya dengan kondisi saat ini.
5. **Bab V Rencana Selanjutnya** berisi rencana implementasi, rancangan pengujian dan evaluasi, serta analisis risiko dan mitigasinya.

BAB II

STUDI LITERATUR

Bab ini menyajikan landasan bagi rumusan masalah pada Subbab I.2. Pembahasan disusun dari kasus menuju teori dan penelitian terdahulu. Pertama, dijelaskan cara kerja Gasper serta serangan dan mitigasinya sebagai kasus yang dikaji. Kedua, dijelaskan teori *reinforcement learning* yang menjadi dasar solusi, lengkap dengan asumsi, keterbatasan, rancangan awal ruang agen, dan batas perubahan parameter. Terakhir, penelitian terdahulu dibandingkan untuk menunjukkan posisi tugas akhir ini dan celah yang diisinya.

II.1 Metode Penelusuran Literatur

Literatur dikumpulkan melalui SLR di basis data Scopus dengan *query* pada Subbab I.6. Literatur dipilih jika (1) terbit di jurnal bereputasi kuartil pertama (Q1) pada tahun 2025 atau sesudahnya, (2) membahas keamanan konsensus *blockchain*, penerapan *reinforcement learning* pada keamanan, atau keduanya, dan (3) menyajikan hasil formal atau empiris yang dapat diverifikasi. Penyaringan menghasilkan empat studi utama yang mewakili empat klaster, yaitu (a) analisis formal Gasper (Laneve & Veschetti, 2025), (b) penerapan AI pada konsensus *blockchain* (Rizal & Kim, 2025), (c) pertahanan adaptif berbasis DRL pada *blockchain* (Skowroński, 2026), dan (d) pelatihan ko-evolusioner penyerang dan pertahanan (Wushishi dkk. 2026).

Kriteria ini sengaja dibuat ketat agar setiap klaim bertumpu pada sumber terverifikasi. Konsekuensinya, karya yang hanya disebut di dalam keempat studi tersebut, misalnya karya prosiding, tidak disintesis langsung. Karya seperti itu hanya dicatat sebagaimana dilaporkan oleh studi utama. Karena itu, klaim celah pada Subbab II.8 hanya berlaku dalam cakupan penelusuran ini.

II.2 Konsensus *Proof-of-Stake* Gasper

II.2.1 Struktur Waktu dan Pemilihan *Proposer*

Gasper membagi waktu ke dalam *slot* berdurasi 12 detik. Pada setiap *slot*, satu validator dipilih secara acak semu melalui RANDAO untuk mengusulkan blok. Sebanyak 32 *slot* membentuk satu *epoch*, dan blok pertama setiap *epoch* disebut *checkpoint*. Untuk menjadi validator, pengguna harus menyetorkan *stake* minimal 32 ETH. Jika *proposer* tidak aktif, *slot* berlalu tanpa blok. Sebaliknya, latensi jaringan dapat membuat beberapa blok diterima pada ketinggian yang sama sehingga terjadi percabangan (*fork*) (Laneve & Veschetti, 2025).

II.2.2 Pemilihan Rantai Utama dan Finalisasi

Gasper menggabungkan dua komponen. LMD-GHOST menyelesaikan *fork* dengan mengambil suara terbaru setiap validator lalu memilih cabang dengan bobot dukungan terbesar. Casper FFG memberikan finalitas melalui dua tahap (Laneve & Veschetti, 2025). Sebuah *checkpoint* c menjadi *justified* jika total *stake* validator yang memilihnya mencapai minimal dua pertiga total *stake*:

$$\sum_{i \in V_c} \mathit{stake}_i \geq \frac{2}{3} \sum_{j \in V} \mathit{stake}_j \tag{II.1}$$

dengan V_c adalah himpunan validator yang memilih c dan V adalah seluruh validator aktif. Sebuah *checkpoint* menjadi *finalized* jika ia dan *checkpoint* berikutnya sama-sama *justified*. Blok yang sudah final tidak dapat dibatalkan, dan sifat inilah yang menjadi dasar *safety* (Laneve & Veschetti, 2025). Karena setiap justifikasi membutuhkan dua pertiga suara, dua *checkpoint* yang saling bertentangan hanya dapat sama-sama final jika sebagian validator memberi suara ganda, dan suara ganda dikenai *slashing*. Sementara itu, *liveness* terjaga jika *checkpoint* baru terus difinalisasi. Pada latensi rata-rata 12,6 detik, peluang justifikasi dalam 64 *slot* adalah 0,552, lebih dari 0,9 dalam 96 *slot*, dan peluang finalisasi dalam 96 *slot* hampir 1 (Laneve & Veschetti, 2025).

II.2.3 Insentif dan Parameter Finalitas

Validator memperoleh *reward* dengan mengusulkan blok dan memberi suara (*attestation*) yang sejalan dengan mayoritas. *Reward* dasar validator i sebanding dengan saldo efektifnya dan berbanding terbalik dengan akar total *stake* (Laneve & Veschet-

ti, 2025):

$$base_reward_i = stake_i \times \frac{64}{4 \times \sqrt{\sum_{j \in V} stake_j}} \tag{II.2}$$

Saldo efektif dibatasi maksimal 32 ETH. Validator yang mengusulkan dua blok pada *slot* yang sama atau memberi suara ganda pada *checkpoint* terkena *slashing*. Sebanyak 1/32 saldonya langsung dihanguskan, ia dikeluarkan selama 36 hari, dan selama masa itu masih dikenai penalti tambahan (Laneve & Veschetti, 2025).

Dua aturan lain memengaruhi finalitas secara langsung. Aturan pertama adalah batas inklusi *attestation*. Suara hanya diterima jika masuk dalam 32 *slot*, dan suara yang melewati batas ini ditolak serta dikenai penalti. Aturan kedua adalah *inactivity leak*. Validator yang tidak aktif kehilangan *stake* secara bertahap sampai keluar dari jaringan, sehingga porsi validator aktif kembali cukup untuk finalisasi (Laneve & Veschetti, 2025). Kedua aturan ini disebut parameter finalitas. Bersama besaran *reward* dan tingkat *slashing*, keduanya menjadi empat parameter yang akan disetel agen pertahanan.

Satu hal perlu dicatat. *Slashing* hanya menghukum pesan ganda. Menahan blok atau suara lalu melepasnya pada waktu tertentu tidak dapat dikenai *slashing*. Karena itu, perilaku menahan hanya dapat ditekan melalui *reward* dan penalti yang terkait ketepatan waktu, yaitu batas inklusi dan *inactivity leak*.

II.3 Serangan Strategis dan Mitigasinya

Serangan strategis adalah penyimpangan yang disengaja dari protokol untuk memperoleh keuntungan lebih besar atau mengganggu jaringan. Serangan yang dianalisis Laneve dan Veschetti (2025) memiliki pola yang sama, yaitu memanipulasi waktu pelepasan blok dan suara, bukan memalsukan pesan.

II.3.1 Penahanan dan Pelepasan Blok

Selfish mining adalah serangan penambangan strategis pada PoW, ketika penambang menahan blok lalu melepasnya pada saat yang tepat agar blok penambang jujur terbuang. Serangan ini sudah lama menjadi sasaran pertahanan, termasuk pertahanan berbasis AI (Skowroński, 2026). Pada Gasper, *fork* dapat muncul secara alami akibat latensi (Laneve & Veschetti, 2025). Penyerang dapat menciptakan *fork* serupa secara sengaja dengan menahan blok dan melepasnya ketika menguntungkan. Pola ini menjadi aksi dasar agen penyerang pada tugas akhir ini.

II.3.2 Serangan *Balancing* dan *Bouncing*

Pada simulasi Laneve dan Veschetti (2025) dengan 13 validator, 4 validator penyerang menjalankan serangan *balancing*. Satu penyerang mengusulkan dua blok pada *slot* yang sama dan mengirim masing-masing ke separuh jaringan. Validator jujur memilih sesuai pandangannya, sedangkan penyerang menahan suaranya lalu melepasnya pada *epoch* berikutnya untuk menyeimbangkan kedua cabang. Akibatnya, tidak ada cabang yang mencapai dua pertiga suara dan finalisasi terhenti. Pada serangan *bouncing*, penyerang menunggu semua validator jujur memberi suara, lalu melepas suaranya untuk menjustifikasi *checkpoint* di cabang yang berganti-ganti. Karena dua *checkpoint* berturutan pada cabang yang sama tidak pernah tercapai, kemampuan finalisasi lumpuh (Laneve & Veschetti, 2025).

Perlu dicatat, hanya pemicu *balancing*, yaitu dua blok pada satu *slot*, yang dapat dikenai *slashing*. Pemicu ini cukup dilakukan satu validator dengan kerugian 1/32 saldonya. Sisa serangan berupa penahanan suara tidak tersentuh *slashing* sama sekali.

II.3.3 *Censorship* terhadap *Attestation*

Proposer menentukan *attestation* mana yang dimasukkan ke bloknya. Suara yang tidak masuk dalam batas inklusi 32 *slot* ditolak dan pemiliknya dikenai penalti (Laneve & Veschetti, 2025). Karena itu, *proposer* penyerang yang tidak menyertakan suara validator jujur dapat membuat suara tersebut kedaluwarsa dan merugikan pemiliknya. Analisis formal pada *Tendermint* yang dirangkum Laneve dan Veschetti (2025) juga menunjukkan bahwa minoritas di atas sepertiga sudah cukup untuk menyensor mayoritas. Pada tugas akhir ini, *censorship* hanya berhasil jika *proposer* penyerang menguasai cukup banyak *slot* di dalam batas inklusi. Dengan demikian, panjang batas inklusi menentukan seberapa mahal *censorship*.

II.3.4 Ambang Kekuatan Penyerang

Dampak serangan bergantung pada porsi *stake* penyerang. Di bawah sepertiga, penyerang tidak dapat menghentikan justifikasi hanya dengan diam, tetapi tetap dapat menggagalkan finalisasi melalui pengaturan waktu suara, seperti pada serangan *balancing* 4 dari 13 validator. Di atas sepertiga, penyerang cukup berhenti memberi suara agar ambang dua pertiga tidak tercapai, dan minoritas sebesar itu sudah mampu menyensor mayoritas. Pada *time attack*, 7 dari 13 validator penyerang memanfaatkan *inactivity leak* untuk menggerus *stake* validator jujur yang tertunda sampai penyerang menguasai dua pertiga suara dan mengendalikan finalisasi (Laneve & Veschetti, 2025). Tugas akhir ini berfokus pada penyerang di bawah sepertiga. Pa-

da wilayah ini, keberhasilan serangan ditentukan oleh strategi, bukan oleh kekuatan suara semata, sehingga parameter insentif paling menentukan.

II.3.5 Mitigasi Saat Ini dan Dilemanya

Mitigasi yang ada berupa tambalan manual. Serangan *balancing* diredam dengan *proposer boost*, yaitu tambahan bobot bagi blok yang tiba tepat waktu. Dengan *boost* 40%, peluang finalisasi kembali menjadi 1 setelah 3 *epoch*. Tambalan *bouncing* berupa batas *slot* pengiriman suara pernah diterapkan, lalu dihapus karena serangan tersebut sulit direproduksi pada Gasper (Laneve & Veschetti, 2025).

Jika ditelaah lebih jauh, setiap parameter memiliki efek dua sisi. Batas inklusi yang ketat menutup ruang penundaan suara, seperti tambalan *bouncing*, tetapi menghukum validator jujur saat latensi tinggi. *Inactivity leak* dirancang untuk memulihkan finalitas, tetapi justru menjadi alat penyerang pada *time attack* (Laneve & Veschetti, 2025). Artinya, nilai terbaik setiap parameter bergantung pada jenis serangan dan kondisi jaringan. Nilai statis yang tepat untuk satu kondisi dapat merugikan pada kondisi lain. Temuan inilah yang menjadi dasar perlunya penyetelan adaptif.

II.4 Pendekatan Analisis Keamanan Konsensus

Terdapat tiga pendekatan untuk menilai ketahanan konsensus terhadap serangan.

Analisis formal stokastik. Laneve dan Veschetti (2025) memodelkan Gasper sebagai komposisi proses *Validator*, *Network*, *Vote_Manager*, *Randao*, *RandaoSelection*, dan *Global* dalam PRISM+. Model dianalisis dengan *statistical model checking* atas 100.000 sampel eksekusi. Pendekatan ini kuat untuk menghitung peluang justifikasi dan finalisasi. Namun, ada tiga kelemahan. Pertama, penyerang ditetapkan sejak awal dan parameter diubah manual. Kedua, tidak ada acuan validasi, sehingga model hanya dibandingkan dengan protokol pendahulu, *Hybrid Casper*. Ketiga, model tersebut tidak sepenuhnya konsisten. Teksnya menyebut *epoch* 32 *slot*, tetapi fungsi penanda *checkpoint* memakai kelipatan 64, dan justifikasi baru mungkin terjadi setelah *slot* 64. Analisis *stake*-nya pun tidak memasukkan *slashing* dan *inactivity leak* (Laneve & Veschetti, 2025). Karena itu, angka dari model ini hanya layak dipakai sebagai acuan verifikasi pada konfigurasi yang sama, bukan sebagai gambaran pasti *Ethereum*.

Analisis berbasis *machine learning*. ML banyak dipakai untuk memprediksi perilaku jaringan dan mendeteksi serangan pada konsensus *blockchain* (Rizal & Kim, 2025). Pendekatan ini membantu mengenali ancaman, tetapi umumnya tidak mengubah aturan protokol.

Penyerang yang belajar. Penyerang dapat dimodelkan sebagai agen RL yang mencari sendiri strategi paling menguntungkan. Pada Wushishi dkk. (2026), agen penyerang berbasis *Q-learning* memilih aksi berdampak tinggi dengan intensitas tertinggi sebanyak 51.706 kali dari 500.000 langkah tanpa diarahkan. Namun, hasil ini hanya bermakna jika pertahanan juga beradaptasi. Studi yang sama menunjukkan bahwa pertahanan yang dievaluasi tanpa penyerang ko-evolusioner menghasilkan kinerja semu yang runtuh saat diuji melawan penyerang adaptif.

Ketiga pendekatan ini saling melengkapi. Analisis formal memberikan acuan verifikasi simulator. ML memberikan cara membaca sinyal ancaman dari data jaringan. Penyerang yang belajar memberikan cara menguji pertahanan secara lebih keras. Tugas akhir ini memakai ketiganya: simulator diverifikasi terhadap model formal, sinyal jaringan dijadikan pengamatan agen, dan pertahanan diuji melawan penyerang yang belajar.

II.5 Dasar Teori *Reinforcement Learning*

II.5.1 *Markov Decision Process* dan Versi Terbatasnya

Reinforcement learning (RL) adalah metode ketika agen belajar mengambil keputusan dengan mencoba aksi dan menerima umpan balik berupa *reward*. Masalah ini dimodelkan sebagai *Markov Decision Process* (MDP) $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, yaitu ruang *state*, ruang aksi, peluang transisi, fungsi *reward*, dan faktor diskon. Tujuan agen adalah menemukan kebijakan π yang memaksimalkan total *reward* jangka panjang.

Pada sistem kritis seperti konsensus, agen tidak boleh mengejar *reward* dengan mengorbankan keselamatan jaringan. Karena itu digunakan *Constrained* MDP (CMDP) yang menambahkan batas pada biaya tertentu (Skowroński, 2026):

$$\max_{\pi} \ \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t r_t\right] \quad \text{dengan syarat} \quad \mathbb{E}_{\pi}[c_i] \leq d_i, \ \ \forall i \tag{II.3}$$

dengan c_i adalah biaya, misalnya tingkat salah tuduh terhadap pihak jujur atau keterlambatan blok, dan d_i adalah batas yang diizinkan. Batas ini dapat ditegakkan melalui *action masking*, yaitu memberi nilai $-\infty$ pada aksi yang melanggar batas sebelum agen memilih aksi (Skowroński, 2026).

II.5.2 *Markov Game* untuk Interaksi Penyerang dan Pertahanan

Ketika dua agen belajar dalam lingkungan yang sama, MDP diperluas menjadi *Markov game*. Wushishi dkk. (2026) merumuskan interaksi pertahanan dan penyerang

sebagai berikut:

$$\mathcal{M} = \left(\mathcal{S}, \mathcal{A}^d, \mathcal{A}^a, P, R^d, R^a, \gamma, \mathcal{C}\right), \qquad P : \mathcal{S} \times \mathcal{A}^d \times \mathcal{A}^a \to \Delta(\mathcal{S}) \tag{II.4}$$

dengan $\mathcal{A}^d$ dan $\mathcal{A}^a$ adalah ruang aksi pertahanan dan penyerang, R^d dan R^a adalah fungsi *reward* masing-masing, $\Delta(\mathcal{S})$ adalah distribusi peluang atas *state*, dan $\mathcal{C}$ adalah himpunan batasan. Pada tugas akhir ini, *reward* penyerang berasal dari keuntungan berlebih atau gangguan finalisasi, sedangkan *reward* pertahanan berasal dari terjaganya *safety*, *liveness*, dan rendahnya profit penyerang. Karena kepentingan keduanya berlawanan, setiap perubahan kebijakan satu agen langsung mengubah lingkungan bagi agen lainnya.

Asumsi. Formulasi ini bertumpu pada empat asumsi.

1. Seluruh validator penyerang bertindak sebagai satu koalisi dengan total *stake* di bawah sepertiga, sesuai Subbab II.3.4.
2. Validator jujur mengikuti protokol secara tetap, seperti pada model Laneve dan Veschetti (2025), sehingga sumber adaptasi hanya kedua agen.
3. Agen pertahanan berperan sebagai lapisan tata kelola protokol. Ia hanya melihat statistik agregat jaringan dan tidak mengetahui identitas penyerang. Dengan demikian, permainan ini teramati sebagian.
4. Sifat Markov didekati dengan memasukkan ringkasan jendela waktu terakhir ke dalam *state*, seperti jendela geser pada Skowroński (2026).

Keterbatasan. Asumsi tersebut membawa tiga keterbatasan.

1. Satu koalisi tidak mewakili kondisi beberapa penyerang independen yang saling bersaing.
2. Permainan ini bukan permainan jumlah nol (*zero-sum*) karena pertahanan juga menanggung biaya berupa *reward* validator jujur yang hilang. Akibatnya, titik keseimbangan tidak dijamin tunggal.
3. Latensi dimodelkan dengan laju rata-rata, seperti pada Laneve dan Veschetti (2025), sehingga keterlambatan ekstrem yang jarang terjadi dapat terlewat.

Keterbatasan ketiga diperiksa saat validasi simulator (RQ1), sedangkan dua keterbatasan pertama dicatat sebagai batas generalisasi hasil.

II.5.3 *Deep Q-Network* dan Variannya

Deep Q-Network (DQN) menaksir nilai $Q(s, a)$, yaitu total *reward* yang diharapkan jika aksi a diambil pada *state* s, menggunakan jaringan saraf. DQN memakai *experience replay* dan jaringan target agar pelatihan stabil. *Double* DQN (DDQN)

mengurangi taksiran nilai yang berlebihan dengan memisahkan pemilihan aksi dan penilaiannya (Skowroński, 2026):

$$y_t = r_t + \gamma\, Q_{\theta^-}\Big(s_{t+1}, \arg\max_{a'} Q_\theta(s_{t+1}, a')\Big) \tag{II.5}$$

dengan θ adalah parameter jaringan utama yang memilih aksi dan θ^- adalah parameter jaringan target yang menilai aksi tersebut. *Dueling network* memisahkan nilai *state* $V(s)$ dan keunggulan aksi $A(s,a)$ (Skowroński, 2026):

$$Q(s,a) = V(s) + \left(A(s,a) - \frac{1}{|\mathcal{A}|}\sum_{a'} A(s,a')\right) \tag{II.6}$$

Prioritized experience replay (PER) menambahkan pengambilan sampel berdasarkan besar galat prediksi agar pola serangan yang jarang tetap dipelajari. Pada Skowroński (2026), gabungan DDQN, *dueling*, dan PER memberi penekanan serangan tertinggi (95,3%) dengan variasi terkecil ($\pm$4,2%) dibanding DQN dasar (89,2%). Aksi diskret juga terbukti lebih cocok untuk konsensus dibanding aksi kontinu. Dibanding *actor-critic* kontinu (DDPG), DQN diskret menghasilkan keluaran identik di semua *node*, lebih mudah diaudit, dan konvergen 11% lebih cepat dengan kinerja setara.

Asumsi. Penerapan DDQN mengasumsikan ruang aksi diskret dan kecil. Asumsi ini terpenuhi karena aksi pertahanan berupa naik, turun, atau tetap pada satu parameter, dan aksi penyerang berupa pilihan diskret di setiap *slot*.

Keterbatasan. Ada tiga keterbatasan.

1. Jaminan konvergensi DQN bergantung pada lingkungan yang stasioner. Skowroński (2026) sendiri mengakui bahwa penyerang yang beradaptasi membuat jaminan tersebut tidak berlaku penuh. Pada pelatihan ko-evolusioner, lawan terus berubah sehingga transisi lama di *replay buffer* dapat usang.
2. Satu jaringan DQN memiliki batas kapasitas. Pada Wushishi dkk. (2026), keunggulan pertahanan DQN mulai hilang pada jaringan di atas 500 perangkat.
3. Keunggulan DQN diskret atas *actor-critic* pada Skowroński (2026) diuji melawan penyerang yang tidak belajar. Keunggulan tersebut pada permainan dua agen belum terbukti.

Keterbatasan pertama ditangani dengan kumpulan lawan pada Subbab II.5.4, keter-

batasan kedua dengan uji skala, dan keterbatasan ketiga dengan menyiapkan *actor-critic* sebagai alternatif pada Bab III.

II.5.4 *Self-Play* dan Kumpulan Lawan

Pada *self-play*, agen pertahanan dilatih melawan agen penyerang yang juga terus belajar sehingga keduanya saling mendorong menjadi lebih kuat. Risikonya, agen pertahanan dapat terlalu menyesuaikan diri dengan lawan terakhir lalu lemah terhadap strategi lama. Wushishi dkk. (2026) mengatasinya dengan menyimpan $K = 10$ potret kebijakan penyerang historis. Pada setiap episode, lawan diambil dari kumpulan tersebut dengan peluang $p_{\text{pool}} = 0{,}30$, dan selebihnya memakai penyerang terkini:

$$\pi^a \sim (1 - p_{\text{pool}})\, \delta_{\pi^a_{\text{kini}}} + \frac{p_{\text{pool}}}{K} \sum_{k=1}^{K} \delta_{\pi^a_{(k)}} \tag{II.7}$$

dengan δ_π adalah distribusi yang seluruh peluangnya berada pada kebijakan π. Dengan cara ini, tingkat mitigasi pertahanan hanya turun 4,9% dari penyerang acak hingga penyerang yang dilatih khusus melawannya (Wushishi dkk. 2026).

Asumsi. Kebijakan penyerang yang tersimpan diasumsikan cukup mewakili ragam strategi penyerang sungguhan. Pada tugas akhir ini, ragam tersebut diperluas dengan dua tujuan penyerang, yaitu mencari keuntungan dan mengganggu finalisasi.

Keterbatasan. Kumpulan lawan selalu terbatas, sehingga ukuran keseimbangan hanya relatif terhadap kumpulan, bukan galat keseimbangan Nash yang formal (Wushishi dkk. 2026). Studi ablasi yang sama juga menunjukkan keragaman kumpulan tidak berpengaruh signifikan secara tersendiri ($d = 0{,}00$), meskipun ikut menjaga ketangguhan keseluruhan. Untuk mengurangi bias ini, kriteria keberhasilan kedua mewajibkan pengujian melawan penyerang yang tidak pernah dilihat selama pelatihan.

II.5.5 Metrik Ketangguhan

Ketangguhan pertahanan diukur terhadap penyerang terkuat, bukan rata-rata. Ukuran pertama adalah profit relatif penyerang, yaitu selisih pendapatan penyerang dengan pendapatan jika ia jujur (Skowroński, 2026):

$$\mathit{Profit}\,(\%) = 100 \times \frac{\mathit{ROI}_{\text{penyerang}} - \mathit{ROI}_{\text{jujur}}}{|\mathit{ROI}_{\text{jujur}}|} \tag{II.8}$$

Nilai positif berarti serangan menguntungkan, sedangkan nilai negatif berarti serangan merugikan penyerang. Ukuran kedua adalah *exploitability*, yaitu seberapa jauh penyerang terbaik dalam kumpulan masih dapat meningkatkan hasilnya terhadap pertahanan yang sudah dibekukan (Wushishi dkk. 2026):

$$\varepsilon_{\text{exploit}} = \max_{\pi^a \in \Pi^a} V^{\pi^a}(\pi^{d*}) - V^{\pi^a_{\text{ko}}}(\pi^{d*}) \tag{II.9}$$

dengan π^{d*} adalah kebijakan pertahanan yang dibekukan, Π^a adalah kumpulan kebijakan penyerang, dan $V^{\pi^a_{\text{ko}}}$ adalah nilai penyerang ko-evolusioner. Semakin kecil nilainya, semakin dekat pasangan kebijakan dengan titik keseimbangan.

II.5.6 Rancangan Awal Ruang *State*, *Action*, dan *Reward*

Tabel II.1 menyajikan rancangan awal ruang agen. Rancangan ini menjadi titik awal untuk menjawab RQ1 dan akan dirinci pada Bab IV. Agen penyerang mengambil keputusan setiap *slot* karena serangan bergantung pada waktu pelepasan blok dan suara. Agen pertahanan mengambil keputusan setiap *epoch* karena parameter pada Subbab II.2.3 bekerja pada skala *epoch*.

Tabel II.1 Rancangan awal ruang *state*, *action*, dan *reward* kedua agen

Komponen	**Agen penyerang**	**Agen pertahanan**
Frekuensi keputusan	Setiap *slot*	Setiap *epoch*
State (pengamatan)	Porsi *stake* koalisi, jadwal *proposer* beberapa *slot* ke depan, selisih bobot antarcabang, jumlah blok dan suara yang ditahan, jarak ke *checkpoint* final terakhir, nilai parameter pertahanan saat ini	Tingkat partisipasi *attestation*, jumlah dan kedalaman *reorg* pada jendela terakhir, jumlah *epoch* sejak finalisasi terakhir, rasio *slot* kosong, rata-rata *reward* validator, jumlah pelanggaran terdeteksi, nilai parameter saat ini
Action	Diskret: mengusulkan blok secara jujur, menahan blok, atau melepas blok yang ditahan; memberi suara tepat waktu, menahan suara, atau melepasnya ke cabang tertentu; tidak menyertakan *attestation* tertentu (*censorship*)	Diskret: menaikkan, menurunkan, atau mempertahankan satu parameter pada Tabel II.2; satu parameter per keputusan
Reward	Profit relatif (Persamaan (II.8)) untuk varian pencari keuntungan, atau lama keterlambatan finalisasi untuk varian pengganggu	Persamaan (II.10)

Fungsi *reward* agen pertahanan dirancang sebagai berikut:

$$R_t^d = -\,w_1\,\mathit{Profit}_t \;-\; w_2\,\mathit{Live}_t \;-\; w_3\,\mathit{Safe}_t \;-\; w_4\,\mathit{Cost}_t \;-\; w_5 \sum_j |\phi_{j,t} - \phi_{j,t-1}| \tag{II.10}$$

dengan keterangan sebagai berikut.

- Profit_t adalah profit relatif penyerang pada *epoch* t.
- Live_t adalah jumlah *epoch* keterlambatan finalisasi di atas toleransi tiga *epoch*. Toleransi ini dipilih karena finalisasi dalam kondisi normal hampir selalu terjadi dalam 96 *slot* atau tiga *epoch* (Laneve & Veschetti, 2025).
- Safe_t bernilai 1 jika dua *checkpoint* yang saling bertentangan sama-sama final, dan 0 jika tidak.
- Cost_t adalah penurunan relatif *reward* validator jujur dibanding parameter bawaan.
- $\phi_{j,t}$ adalah nilai parameter ke-j pada *epoch* t, dan $w_1, \ldots, w_5$ adalah bobot setiap komponen.

Struktur ini mengikuti Skowroński (2026) yang menggabungkan profit penyerang, gangguan *liveness*, biaya perubahan parameter, dan biaya salah tuduh terhadap pihak jujur. Bobot w_3 ditetapkan paling besar karena pelanggaran *safety* tidak dapat dipulihkan. Suku w_5 mencegah agen mengubah parameter terlalu sering. Nilai bobot dipilih melalui pencarian *grid* dan uji sensitivitas, seperti pada Skowroński (2026) dan Wushishi dkk. (2026).

II.5.7 Batas Perubahan Parameter Konsensus

Agar kebijakan pertahanan tidak melanggar spesifikasi dasar protokol, sebagaimana disyaratkan RQ1, parameter dibagi menjadi dua kelompok. Kelompok pertama adalah invarian yang dikunci, yaitu ambang dua pertiga pada Persamaan (II.1), durasi *slot* 12 detik, panjang *epoch* 32 *slot*, *stake* minimal 32 ETH, dan aturan pemilihan rantai termasuk *proposer boost*. Ambang dua pertiga dikunci karena menurunkannya langsung melemahkan jaminan *safety* pada Subbab II.2. Kelompok kedua adalah empat parameter yang boleh disetel, seperti pada Tabel II.2.

Setiap keputusan agen pertahanan juga harus memenuhi batasan berikut:

$$\phi_j^{\min} \le \phi_{j,t} \le \phi_j^{\max}, \qquad |\phi_{j,t} - \phi_{j,t-1}| \le \Delta_j, \qquad \sum_j \mathbf{1}[\phi_{j,t} \ne \phi_{j,t-1}] \le 1, \qquad |\phi_{j,t} - \phi_{j,t-H}| \le \delta_j^{\text{ma}} \tag{II.11}$$

Tabel II.2 Rancangan awal parameter yang dapat disetel agen pertahanan beserta batas perubahannya

Parameter	**Nilai acuan**	**Rentang awal**	**Langkah per keputusan**
Pengali *reward* dasar κ_r	1 (Persamaan (II.2))	[0,8; 1,2]	5% nilai acuan
Pengali penalti *slashing* κ_s	1, setara 1/32 saldo (Laneve & Veschetti, 2025)	[0,5; 2,0]	5% nilai acuan
Batas inklusi *attestation* λ_{inc}	32 *slot* (Laneve & Veschetti, 2025)	[16; 32] *slot*	4 *slot*
Pengali laju *inactivity leak* κ_l	1 (Laneve & Veschetti, 2025)	[0,5; 2,0]	5% nilai acuan

dengan $\phi_j^{\min}$ dan $\phi_j^{\max}$ adalah batas rentang, Δ_j adalah langkah maksimum per keputusan, $\mathbf{1}[\cdot]$ bernilai 1 jika kondisinya benar, dan $\delta_j^{\max}$ adalah perubahan kumulatif maksimum dalam jendela H *epoch*. Setiap batasan didasarkan pada temuan Skowroński (2026) berikut.

- Langkah 5% dipilih karena langkah 1% membuat parameter berganti terlalu sering, sedangkan langkah 10 sampai 15% membuat parameter melampaui nilai yang tepat.
- Hanya satu parameter yang boleh berubah per keputusan karena mengubah beberapa parameter sekaligus memperlambat pelatihan (347 ribu berbanding 197 ribu langkah) tanpa menaikkan kinerja.
- Batas perubahan kumulatif meniru batas pergeseran harian yang mencegah agen menggeser parameter sedikit demi sedikit hingga jauh dari nilai aman.

Seluruh batasan ditegakkan dengan *action masking*. Skowroński (2026) melaporkan nol pelanggaran batas dalam 30 kali uji dengan cara ini, dan Wushishi dkk. (2026) memakai mekanisme serupa untuk batas anggaran pertahanan. Batas atas λ_{inc} ditetapkan 32 *slot* karena suara di luar *epoch* yang sama memang tidak diterima (Laneve & Veschetti, 2025). Rentang lainnya merupakan rancangan awal penulis dan akan dikalibrasi pada Bab IV agar perilaku normal simulator tetap sesuai dengan data *on-chain*.

II.6 Penerapan AI pada Konsensus *Blockchain*

Rizal dan Kim (2025) menyaring lebih dari 500 makalah terbitan 2010 sampai 2023 menjadi 120 makalah dan memetakan tiga fungsi AI pada konsensus. Fungsi pertama adalah prediksi, misalnya validator berikutnya, biaya transaksi, atau peluang *fork*. Fungsi kedua adalah deteksi anomali dan serangan, misalnya serangan Sybil dan *double spending*. Fungsi ketiga adalah konsensus adaptif. Contohnya, protokol Sabine mengatur jumlah validator PBFT dengan model regresi dan menekan seli-

sih antara target dan capaian *throughput* menjadi 7,79%, jauh di bawah 39,5% pada rantai konvensional. Survei ini juga mencatat risiko integrasi AI, yaitu beban komputasi, sentralisasi, kerentanan terhadap serangan adversarial, dan sifat kotak hitam yang sulit diaudit. *Blockchain* yang menyetel parameternya sendiri ditempatkan sebagai arah riset ke depan, bukan praktik yang sudah mapan.

Dua catatan kritis perlu diberikan. Pertama, cakupan survei berhenti pada 2023 sehingga perkembangan pertahanan berbasis RL sesudahnya tidak terekam. Kedua, contoh konsensus adaptif seperti Sabine mengoptimalkan kinerja, bukan ketahanan terhadap penyerang yang belajar. Risiko sentralisasi dan kotak hitam menjadi alasan rancangan pada Subbab II.5.7 hanya mengizinkan perubahan parameter yang berlaku sama bagi semua validator dan tercatat jelas setiap langkahnya.

II.7 Pertahanan Adaptif Berbasis *Reinforcement Learning*

Skowroński (2026) meneliti *wave attack* pada PoW, yaitu serangan ketika penambang mengatur naik turunnya partisipasi untuk mengeksploitasi algoritma penyesuaian kesulitan. Pertahanan statis awalnya membuat serangan merugi, tetapi penyerang yang menguji batas ambang secara bertahap kembali untung setelah sekitar 20 hari. Penulis lalu menambahkan agen DDQN yang menyetel ambang deteksi dan masa jeda dalam kerangka CMDP dengan *action masking*. Dalam 30 kali uji, profit penyerang tetap negatif ($-42 \pm 13\%$), dibanding $+65 \pm 22\%$ pada pertahanan statis, tanpa pelanggaran batas keselamatan. Pengendali adaptif lain yang tidak berbasis DRL, yaitu *Thompson sampling*, PID, EWMA, dan *contextual bandit*, tetap membiarkan profit penyerang positif antara $+58\%$ dan $+92\%$.

Wushishi dkk. (2026) meneliti penipuan siber pada IIoT dengan melatih agen pertahanan DQN secara ko-evolusioner melawan agen penyerang *Q-learning* dan kumpulan penyerang historis. Pertahanan tanpa penyerang ko-evolusioner turun tingkat mitigasinya dari 0,778 menjadi 0,681 saat menghadapi penyerang adaptif, sedangkan pertahanan ko-evolusioner hanya turun dari 0,836 menjadi 0,803. Pasangan kebijakan yang dihasilkan memiliki *exploitability* 4,43% relatif terhadap kumpulan penyerang.

Kedua studi saling menguatkan. Skowroński (2026) menunjukkan apa yang perlu disetel dan bagaimana membatasinya dengan aman, tetapi penyerangnya tidak belajar. Wushishi dkk. (2026) menunjukkan bagaimana melatih pertahanan melawan penyerang yang belajar, tetapi di luar domain *blockchain*. Tugas akhir ini mengambil cara pembatasan dari studi pertama dan skema pelatihan dari studi kedua, lalu menerapkannya pada parameter insentif Gasper.

II.8 Penelitian Terkait dan Posisi Tugas Akhir

II.8.1 Studi Primer Terdekat

Dalam cakupan penelusuran, studi primer yang paling dekat dengan tugas akhir ini adalah Skowroński (2026). Studi ini memenuhi tiga unsur sekaligus, yaitu domain *blockchain*, agen DRL yang mengubah parameter pertahanan, dan penyerang yang beradaptasi. Namun, ada empat perbedaan penting.

1. Penyerangnya tidak belajar. Penyerang hanya menurunkan atau menaikkan amplitudo serangan setiap lima hari berdasarkan aturan tetap. Penulisnya sendiri menyebut penyerang berbasis DRL sebagai ancaman yang belum diuji.
2. Yang disetel adalah ambang deteksi dan masa jeda, bukan insentif ekonomi seperti *reward* dan *slashing*.
3. Domainnya PoW dengan algoritma penyesuaian kesulitan, bukan PoS dengan aturan justifikasi dan finalisasi.
4. Hasilnya berasal dari simulasi 128 *node*, dan *reward*-nya memakai tingkat salah tuduh yang membutuhkan label pihak jujur saat pelatihan.

Skowroński (2026) juga melaporkan tiga karya lain yang tidak memenuhi kriteria seleksi sehingga tidak disintesis langsung. Karya pertama menggabungkan DQN dan PPO untuk pemilihan validator dinamis pada *Ethereum* dan *Hyperledger*. Karya kedua memakai PPO untuk optimasi konsensus adaptif dengan validasi adversarial. Karya ketiga, MRL-PoS, adalah algoritma konsensus PoS berbasis MARL dengan pelatihan *self-play*. Sejauh dilaporkan, ketiganya merancang mekanisme konsensus baru atau parameter operasional, bukan menyetel parameter insentif Gasper dalam batas invarian protokol. Keberadaan MRL-PoS menunjukkan bahwa gagasan MARL untuk PoS bukan hal baru. Karena itu, kebaruan tugas akhir ini tidak diklaim sebagai MARL pertama untuk PoS, tetapi dibatasi pada kombinasi yang lebih spesifik pada Subbab II.8.3.

II.8.2 Perbandingan Penelitian Terkait

Tabel II.3 merangkum perbandingan keempat studi utama, termasuk bagian yang diadopsi tugas akhir ini.

II.8.3 Celah Penelitian dalam Cakupan Penelusuran

Berdasarkan Tabel II.3, dan dalam batas cakupan penelusuran pada Subbab II.1, teridentifikasi tiga celah berikut.

1. **Penyerang yang belajar belum diuji pada Gasper.** Analisis Gasper yang ditemukan masih memakai penyerang terskenario (Laneve & Veschetti, 2025), dan pertahanan DRL pada *blockchain* masih menghadapi penyerang berbasis

Tabel II.3 Perbandingan penelitian terkait dan bagian yang diadopsi tugas akhir ini

Penelitian	**Objek**	**Penyerang**	**Yang diatur pertahanan**	**Keterbatasan utama**	**Yang diadopsi TA ini**
Laneve & Veschetti (2025)	Gasper	Terskenario	Tidak ada (tambalan manual)	Penyerang tidak adaptif, tanpa acuan validasi	Struktur modul simulator, angka acuan verifikasi, skenario serangan
Rizal & Kim (2025)	Umum (survei)	–	Prediksi, deteksi, kinerja	Cakupan hingga 2023, konsensus adaptif masih arah riset	Peta pendekatan AI, risiko sentralisasi dan kotak hitam
Skowroński (2026)	PoW	Adaptif berbasis aturan	Ambang deteksi, masa jeda	Bukan PoS, penyerang tidak belajar	CMDP, DDQN, *action masking*, langkah 5%, profit relatif, validasi simulator
Wushishi dkk. (2026)	IIoT	Agen RL koevolusioner	Profil pertahanan	Bukan *blockchain*, keseimbangan relatif terhadap kumpulan	Kumpulan penyerang historis, tiga rezim penyerang uji, uji statistik
Tugas akhir ini	**Gasper**	**Agen RL koevolusioner**	***Reward*, *slashing*, parameter finalitas**	–	–

aturan (Skowroński, 2026).

2. **Pertahanan adaptif belum menyentuh parameter insentif PoS.** Pertahanan RL yang ditemukan menyetel ambang deteksi (Skowroński, 2026) atau profil pertahanan jaringan (Wushishi dkk. 2026). Belum ditemukan studi yang menyetel *reward*, *slashing*, dan parameter finalitas dengan batas yang menjaga invarian protokol.
3. **Pelatihan dua sisi belum diterapkan pada finalitas Gasper.** Pelatihan koevolusioner terbukti efektif pada domain keamanan lain (Wushishi dkk. 2026), dan perluasannya ke PoS diusulkan sebagai pekerjaan lanjutan (Skowroński, 2026). Namun, dalam literatur yang ditelusuri, belum ada yang melatih penyerang dan pertahanan bersamaan pada aturan justifikasi dan finalisasi Gasper.

Klaim memiliki dua batasan utama. Pertama, klaim tersebut berarti belum ditemukan dalam cakupan penelusuran, bukan belum pernah diteliti. Kedua, bidang ini berkembang cepat sehingga penelusuran akan diperbarui sebelum laporan akhir disusun. Dengan batasan tersebut, proposal tugas akhir ini mengisi ketiga celah dengan membangun arena berbasis simulator Gasper. Di dalam arena ini, agen penyerang dan agen pertahanan dilatih bersamaan, dan agen pertahanan menyetel *reward*, *slashing*, serta parameter finalitas dalam batas pada Subbab II.5.7. Celah pertama dijawab melalui RQ3, celah kedua melalui RQ1, dan celah ketiga melalui RQ2. Kebutuhan dan pemilihan solusinya dianalisis pada Bab III.

BAB III

ANALISIS MASALAH

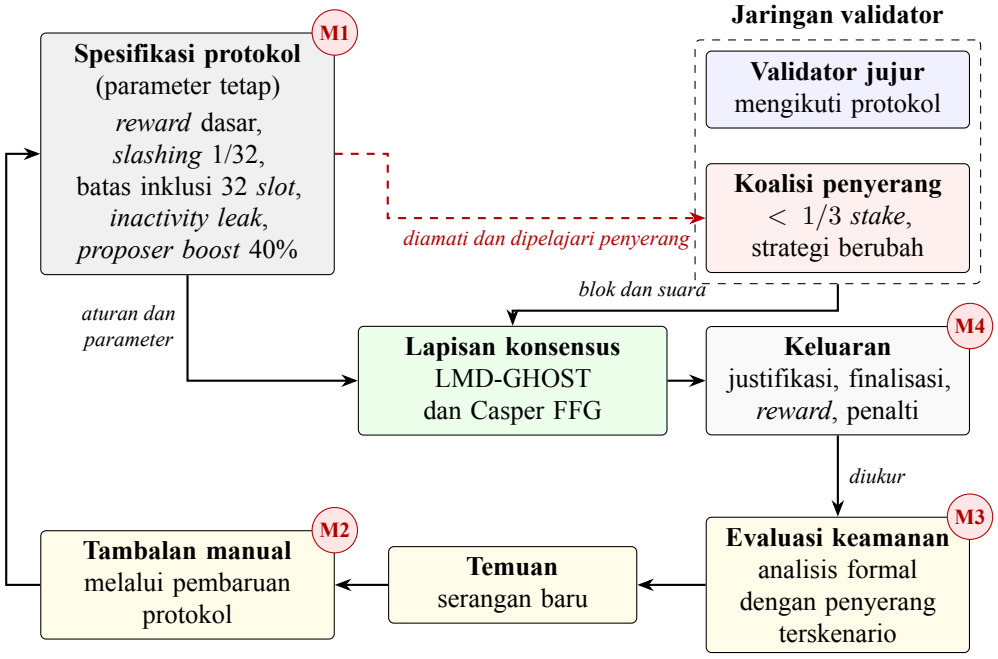
Bab ini menganalisis masalah dari kondisi saat ini, menurunkan kebutuhan solusi, lalu memilih solusi secara terukur. Analisis dilakukan dengan studi kasus dokumen terhadap empat studi utama pada Bab II. Cara ini dipilih karena tugas akhir ini bersifat penelitian dan objeknya adalah protokol publik, bukan organisasi tertentu yang dapat diwawancarai.

III.1 Analisis Kondisi Saat Ini

Gambar III.1 menunjukkan model konseptual sistem pertahanan Gasper saat ini. Sistem ini terdiri atas lima komponen. Komponen pertama adalah spesifikasi protokol yang memuat parameter tetap, yaitu *reward* dasar, *slashing* 1/32 saldo, batas inklusi 32 *slot*, *inactivity leak*, dan *proposer boost* 40% (Laneve & Veschetti, 2025). Komponen kedua adalah jaringan validator yang terdiri atas validator jujur dan koalisi penyerang. Komponen ketiga adalah lapisan konsensus LMD-GHOST dan Casper FFG. Komponen keempat adalah keluaran berupa justifikasi, finalisasi, *reward*, dan penalti. Komponen kelima adalah siklus evaluasi dan tambalan, yaitu analisis formal dengan penyerang terskenario, temuan serangan baru, lalu tambalan manual melalui pembaruan protokol.

Interaksi antarkomponen berjalan sebagai berikut. Spesifikasi memberi aturan dan parameter kepada lapisan konsensus. Validator mengirim blok dan suara, lalu lapisan konsensus menghasilkan justifikasi, finalisasi, *reward*, dan penalti. Keluaran tersebut dinilai melalui analisis formal yang memakai penyerang terskenario (Laneve & Veschetti, 2025). Jika serangan baru ditemukan, tambalan dirancang manual lalu dimasukkan ke spesifikasi. Persoalannya, siklus ini lambat dan bergantung pada manusia, sedangkan penyerang dapat mengamati parameter yang tetap dan menyesuaikan strateginya kapan saja. Dari model ini teridentifikasi empat masalah berikut.

M1. Parameter tetap dapat dipelajari penyerang. Seluruh parameter insentif Gasper bernilai tetap. Penyerang adaptif cukup menguji batasnya secara bertahap. Pada PoW, penyerang menemukan amplitudo serangan 0,75 yang lolos deteksi sam-



Gambar III.1 Model konseptual sistem pertahanan Gasper saat ini. Label M1 sampai M4 menandai letak masalah pada Tabel III.1

bil mempertahankan sekitar 40% keuntungan, sehingga pertahanan statis ditembus dalam sekitar 20 hari (Skowroński, 2026). Gasper tidak memiliki mekanisme yang mencegah pola penyesuaian serupa.

M2. Mitigasi bersifat reaktif, khusus, dan bermata dua. *Proposer boost* hanya ditujukan untuk *balancing*, sedangkan tambalan *bouncing* pernah diterapkan lalu dihapus (Laneve & Veschetti, 2025). Setiap parameter juga memiliki efek dua sisi, seperti dijelaskan pada Subbab II.3.5. Selain itu, *slashing* tidak menyentuh perilaku menahan blok dan suara, sehingga menaikkan *slashing* saja tidak cukup. Belum ada mekanisme yang menimbang efek dua sisi tersebut sesuai kondisi serangan.

M3. Evaluasi terhadap penyerang tetap melebihkan ketangguhan. Analisis formal memakai penyerang terskenario dan harus diulang untuk setiap varian (Laneve & Veschetti, 2025). Bukti dari domain lain menunjukkan bahayanya. Pertahanan yang dilatih tanpa penyerang ko-evolusioner menghasilkan *reward* 146,41 dan tingkat mitigasi 0,8236 yang tampak tinggi, tetapi angka itu semu dan runtuh saat diuji melawan penyerang adaptif (Wushishi dkk. 2026). Masalah ini diperparah oleh tidak adanya acuan validasi model Gasper. Laneve dan Veschetti (2025) hanya dapat membandingkan modelnya dengan *Hybrid Casper*, dan modelnya pun tidak konsisten soal panjang *epoch*.

M4. Biaya pertahanan bagi validator jujur tidak terukur. Analisis *stake* pada Laneve dan Veschetti (2025) tidak memasukkan *slashing* dan *inactivity leak*, padahal *time attack* menunjukkan bahwa validator jujur yang tertunda justru kehilangan *stake* karena *inactivity leak*. Sebaliknya, Skowroński (2026) mengukur biaya pertahanan bagi pihak jujur secara eksplisit melalui tingkat salah tuduh 3,8%. Tanpa ukuran serupa, suatu pertahanan bisa tampak aman tetapi memindahkan beban ke validator jujur. Kondisi ini juga berisiko mendorong sentralisasi (Rizal & Kim, 2025).

Ringkasan keempat masalah disajikan pada Tabel III.1.

Tabel III.1 Masalah pada sistem pertahanan Gasper saat ini

ID	Masalah	Bukti	Dampak
M1	Parameter tetap dapat dipelajari penyerang	Pertahanan statis ditembus dalam sekitar 20 hari, profit -95% menjadi $+65\%$ (Skowroński, 2026)	Nilai yang dinilai aman kehilangan efektivitas
M2	Mitigasi reaktif, khusus, dan bermata dua	*Proposer boost* tetap 40%, tambalan *bouncing* dihapus, *inactivity leak* dipakai penyerang (Laneve & Veschetti, 2025)	Satu nilai statis tidak tepat untuk semua kondisi
M3	Evaluasi terhadap penyerang tetap melebihkan ketangguhan	Penyerang terskenario dan tanpa acuan validasi (Laneve & Veschetti, 2025), kinerja semu tanpa ko-evolusi (Wushishi dkk. 2026)	Kesimpulan aman yang menyesatkan
M4	Biaya bagi validator jujur tidak terukur	Analisis tanpa *slashing* dan *inactivity leak* (Laneve & Veschetti, 2025), risiko sentralisasi (Rizal & Kim, 2025)	Pertahanan memindahkan beban ke pihak jujur

III.2 Analisis Kebutuhan

Kebutuhan diturunkan dari masalah M1 sampai M4 dan dari praktik yang terbukti pada empat studi utama. Setiap kebutuhan diberi dasar literatur agar dapat dipertanggungjawabkan pada tahap evaluasi.

III.2.1 Identifikasi Masalah Pengguna

Pengguna hasil tugas akhir ini adalah empat pemangku kepentingan pada Tabel III.2. Peneliti keamanan dan perancang protokol menjadi pengguna langsung arena. Validator jujur dan pengguna jaringan menjadi pihak yang menerima dampak kebijakan pertahanan.

Tabel III.2 Masalah dan kebutuhan setiap pemangku kepentingan

Pengguna	Masalah yang dihadapi	Kebutuhan	Terkait
Peneliti keamanan protokol	Analisis formal harus diulang untuk setiap varian serangan, dan tidak ada penyerang yang mencari celah sendiri (Laneve & Veschetti, 2025)	Arena yang menghasilkan penyerang adaptif secara otomatis di atas simulator tervalidasi	M3
Perancang protokol dan tata kelola	Tambalan diputuskan per serangan tanpa bukti lintas kondisi (Laneve & Veschetti, 2025)	Rekomendasi parameter yang teruji melawan berbagai penyerang, aman, dan dapat diaudit sebelum diusulkan (Skowroński, 2026)	M1, M2
Validator jujur	Menanggung penalti inklusi dan *inactivity leak* saat latensi tinggi atau disensor (Laneve & Veschetti, 2025)	Pertahanan yang tidak memindahkan biaya kepada validator jujur	M4
Pengguna jaringan	Finalisasi yang tertunda menahan transaksi (Laneve & Veschetti, 2025)	Jaminan *safety* dan *liveness* yang terukur	M2, M3

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional adalah kemampuan yang harus dimiliki arena agar keempat masalah dapat dijawab. Daftarnya disajikan pada Tabel III.3.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional menetapkan mutu arena. Setiap kebutuhan diberi kriteria terukur pada Tabel III.4. Angka yang tidak berasal dari literatur merupakan target rancangan penulis.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Berdasarkan Bab II, terdapat enam alternatif solusi. Bukti dan kelemahan setiap alternatif dirangkum pada Tabel III.5.

1. **A1, parameter statis dengan analisis formal berulang.** Ini adalah kondisi saat ini. Analisis formal mengukur peluang justifikasi dan finalisasi dengan presisi, tetapi penyerangnya terskenario dan setiap varian harus dianalisis ulang secara manual (Laneve & Veschetti, 2025).
2. **A2, deteksi berbasis ML tanpa penyetelan parameter.** ML dapat memprediksi dan mendeteksi serangan (Rizal & Kim, 2025). Namun, pada PoW, klasifikator terawasi hanya mencapai F1 0,78 karena gagal mengenali varian

Tabel III.3 Kebutuhan fungsional arena penyerang dan pertahanan

ID	Kebutuhan	Dasar	Masalah
KF-01	Mensimulasikan siklus *slot* dan *epoch* Gasper, yaitu pemilihan *proposer* acak, propagasi blok dengan latensi, *attestation*, LMD-GHOST, serta justifikasi dan finalisasi dua pertiga	Struktur modul Laneve & Veschetti (2025)	M3
KF-02	Menghitung *reward*, penalti inklusi, *inactivity leak*, dan *slashing* setiap *epoch* sesuai nilai parameter yang sedang berlaku	Laneve & Veschetti (2025)	M2, M4
KF-03	Menyediakan aksi dasar penyerang, yaitu menahan dan melepas blok, menahan dan melepas suara ke cabang tertentu, serta tidak menyertakan *attestation*, termasuk skenario *balancing* 4 dari 13 validator untuk verifikasi	Laneve & Veschetti (2025)	M3
KF-04	Menyediakan antarmuka *Markov game* dua agen dengan frekuensi keputusan berbeda (*slot* dan *epoch*), pengamatan sebagian bagi pertahanan, dan *reward* terpisah	Wushishi dkk. (2026)	M1
KF-05	Menyetel empat parameter secara diskret, satu parameter per keputusan, dengan *action masking* untuk rentang, langkah, dan pergeseran kumulatif	Skowroński (2026)	M1, M2
KF-06	Melatih kedua agen secara ko-evolusioner dengan kumpulan potret penyerang historis	Wushishi dkk. (2026)	M1, M3
KF-07	Mengevaluasi pertahanan melawan tiga rezim penyerang dan membandingkannya dengan pertahanan statis, berbasis aturan, dan DRL satu sisi	Wushishi dkk. (2026), Skowroński (2026)	M3
KF-08	Mencatat profit relatif, pelanggaran *safety*, keterlambatan finalisasi, biaya pertahanan, *exploitability*, dan jejak perubahan parameter	Skowroński (2026), Wushishi dkk. (2026)	M3, M4

Tabel III.4 Kebutuhan nonfungsional beserta kriteria terukurnya

ID	**Atribut**	**Kriteria terukur**	**Dasar**
KNF-01	Fidelitas	Pada konfigurasi Laneve & Veschetti (2025), peluang justifikasi dan finalisasi berselisih paling besar 0,05 dari acuan. Pada konfigurasi kalibrasi, metrik normal lolos uji Kolmogorov-Smirnov ($p > 0{,}05$)	Laneve & Veschetti (2025), Skowroński (2026)
KNF-02	Kepatuhan invarian	Nol pelanggaran invarian dan batas parameter di seluruh pelatihan dan pengujian	Skowroński (2026)
KNF-03	Determinisme	Aksi diskret, *seed* tercatat, dan kebijakan dibekukan saat pengujian sehingga hasil dapat diulang identik	Skowroński (2026)
KNF-04	Ketelitian statistik	Pelatihan dengan minimal 10 *seed*, pengujian 30 kali, uji Wilcoxon dengan koreksi Bonferroni, dan Cohen's d	Wushishi dkk. (2026), Skowroński (2026)
KNF-05	Efisiensi	Satu sesi pelatihan selesai paling lama 24 jam pada CPU *multi-core* dan satu GPU kelas menengah (target penulis)	Acuan 8 jam per 200 ribu langkah (Skowroński, 2026)
KNF-06	Skalabilitas	Kinerja kebijakan pada 256 validator turun paling banyak 5% dari kinerja pada 64 validator (target penulis), lalu diuji hingga 1.000 validator	Wushishi dkk. (2026)
KNF-07	Keadilan	Perubahan parameter berlaku seragam untuk semua validator, tanpa perlakuan berdasarkan identitas	Rizal & Kim (2025)
KNF-08	Keterjelasan	Setiap perubahan parameter tercatat bersama *state* pemicunya, dan sebaran aksi dilaporkan	Skowroński (2026), Rizal & Kim (2025)

baru, dan detektor GAN mencapai 0,86 (Skowroński, 2026). Alternatif ini juga tidak mengubah insentif.

3. **A3, pengendali adaptif non-DRL.** Pengendali berbasis aturan, PID, EWMA, dan *bandit* menyetel parameter secara otomatis, tetapi tidak mengantisipasi perubahan strategi. Profit penyerang tetap positif antara $+58\%$ dan $+92\%$ (Skowroński, 2026).
4. **A4, DRL satu sisi melawan penyerang tetap.** Agen DRL menekan profit penyerang berbasis aturan hingga -42% (Skowroński, 2026). Namun, pertahanan yang dilatih melawan penyerang tetap turun tingkat mitigasinya dari 0,778 menjadi 0,681 ketika lawannya ikut belajar (Wushishi dkk. 2026).
5. **A5, model permainan analitis (Stackelberg).** Model ini memiliki penurunan kinerja terkecil antarrezim penyerang (skor 0,0892), tetapi mengasumsikan penyerang mengetahui struktur permainan secara penuh, dan tingkat mitigasinya di bawah pertahanan ko-evolusioner (0,753 berbanding 0,803) (Wushishi dkk. 2026). Ruang strategi penyerang Gasper yang diputuskan setiap *slot* juga terlalu besar untuk diselesaikan secara analitis.
6. **A6, MARL ko-evolusioner dengan kumpulan penyerang dan *action masking*.** Pertahanan dilatih bersama penyerang yang belajar dan kumpulan penyerang historis (Wushishi dkk. 2026), sedangkan perubahan parameter dibatasi dengan *action masking* (Skowroński, 2026). Kelemahannya, alternatif ini belum diuji pada *blockchain*, konvergensinya tidak dijamin, dan biaya komputasinya lebih besar.

III.3.2 Analisis Penentuan Solusi

Alternatif dinilai dengan enam kriteria yang diturunkan langsung dari masalah dan kebutuhan pada Subbab III.1 dan III.2.

1. **K1, tangguh terhadap penyerang yang belajar** (M1, M3, KF-06, KF-07).
2. **K2, menyetel parameter insentif**, bukan hanya mendeteksi (M2, KF-05).
3. **K3, menjaga invarian protokol** (KNF-02).
4. **K4, tidak bergantung pada label serangan atau pengetahuan penuh tentang penyerang** (KF-04).
5. **K5, deterministik dan dapat diaudit** (KNF-03, KNF-08).
6. **K6, layak secara komputasi** (KNF-05).

Hasil penilaian disajikan pada Tabel III.6. K1 menjadi kriteria penentu karena merupakan inti masalah tugas akhir ini.

A6 adalah satu-satunya alternatif yang memenuhi K1 sampai K5. A3 dan A4 unggul pada kemudahan, tetapi gagal pada K1 yang menjadi inti masalah. A5 kuat

Tabel III.5 Ringkasan alternatif solusi beserta bukti dan kelemahannya

Kode	Alternatif	Bukti utama	Kelemahan utama
A1	Parameter statis dan analisis formal	Peluang finalisasi terukur presisi (Laneve & Veschetti, 2025)	Penyerang terskenario, analisis ulang manual
A2	Deteksi ML tanpa penyetelan	F1 0,78 (terawasi) dan 0,86 (GAN) (Skowroński, 2026)	Tidak mengubah insentif, gagal pada varian baru
A3	Pengendali adaptif non-DRL	Profit penyerang $+58\%$ sampai $+92\%$ (Skowroński, 2026)	Tidak mengantisipasi perubahan strategi
A4	DRL satu sisi	Profit -42% melawan penyerang berbasis aturan (Skowroński, 2026)	Mitigasi turun 0,778 ke 0,681 melawan penyerang adaptif (Wushishi dkk. 2026)
A5	Permainan analitis (Stackelberg)	Penurunan terkecil, skor 0,0892 (Wushishi dkk. 2026)	Butuh pengetahuan penuh, mitigasi absolut lebih rendah
A6	MARL ko-evolusioner dengan *action masking*	Mitigasi 0,803 melawan penyerang adaptif, nol pelanggaran batas (Skowroński, 2026; Wushishi dkk. 2026)	Belum diuji pada *blockchain*, konvergensi tidak dijamin

Tabel III.6 Penilaian alternatif solusi terhadap kriteria pemilihan

Alternatif	K1	K2	K3	K4	K5	K6
A1 Parameter statis dan analisis formal	×	○	✓	×	✓	✓
A2 Deteksi ML tanpa penyetelan	○	×	✓	○	○	✓
A3 Pengendali adaptif non-DRL	×	✓	✓	✓	✓	✓
A4 DRL satu sisi	○	✓	✓	○	✓	✓
A5 Permainan analitis	○	✓	✓	×	✓	○
A6 MARL ko-evolusioner	✓	✓	✓	✓	✓	○
Keterangan: ✓ terpenuhi, ○ terpenuhi sebagian, × tidak terpenuhi.						

secara teori, tetapi gagal pada K4 karena penyerang nyata tidak terikat pada struktur permainan yang diasumsikan. Kelemahan A6 pada K6 masih dapat diterima karena satu sesi pelatihan DRL pada Skowroński (2026) selesai sekitar 8 jam, dan pelatihan ko-evolusioner pada Wushishi dkk. (2026) konvergen pada episode ke-1.377 dari 5.000. Karena itu, A6 dipilih sebagai solusi.

Setelah alternatif ditentukan, algoritma pembelajarannya perlu dipilih. Dua keluarga dibandingkan pada Tabel III.7, yaitu keluarga DQN dan keluarga *actor-critic* seperti DDPG dan PPO.

Tabel III.7 Perbandingan keluarga algoritma untuk kedua agen

Aspek	**Keluarga DQN (DDQN, *dueling*)**	**Keluarga *actor-critic* (DDPG, PPO)**
Kecocokan dengan aksi diskret	Langsung sesuai	DDPG dirancang untuk aksi kontinu (Skowroński, 2026)
Determinisme keluaran	100% identik antar-*node* (Skowroński, 2026)	DDPG 99,7% karena galat pembulatan (Skowroński, 2026)
Stabilitas pelatihan	Konvergen 197 ribu langkah, variasi $\pm$4,2% (Skowroński, 2026)	DDPG 221 ribu langkah dan butuh penyetelan cermat (Skowroński, 2026)
Bukti pada pelatihan ko-evolusioner	Pertahanan DQN terbukti, dan menghapus DQN menurunkan *reward* 23% (Wushishi dkk. 2026)	PPO pada IIoT hanya diuji melawan ancaman yang berubah, bukan penyerang ko-evolusioner (Wushishi dkk. 2026)

Bukti pada keempat studi utama lebih kuat untuk keluarga DQN. Karena itu, agen pertahanan memakai DDQN dengan *dueling network* dan PER, mengikuti konfigurasi terbaik Skowroński (2026). Agen penyerang juga memakai DDQN. *Q-learning* tabel seperti pada Wushishi dkk. (2026) tidak dipakai karena pengamatan penyerang memuat nilai kontinu seperti selisih bobot antarcabang, sehingga tabel tidak praktis. Keluarga *actor-critic* disiapkan sebagai alternatif jika pelatihan DDQN tidak konvergen akibat lawan yang terus berubah, sesuai keterbatasan pada Subbab II.5.3.

Solusi terpilih terdiri atas enam komponen, yaitu simulator Gasper, agen penyerang, agen pertahanan, lapisan *action masking*, kumpulan penyerang historis, dan modul evaluasi. Keterlacakan antara masalah, kebutuhan, komponen, dan pertanyaan penelitian disajikan pada Tabel III.8. Rancangan rinci setiap komponen dan perbandingannya dengan Gambar III.1 disajikan pada Bab IV.

Pilihan ini membawa empat risiko yang perlu diantisipasi. Pertama, pelatihan ko-evolusioner dapat berputar tanpa konvergen. Kedua, *exploitability* hanya relatif terhadap kumpulan penyerang (Wushishi dkk. 2026). Ketiga, hasil simulasi belum

Tabel III.8 Keterlacakan masalah, kebutuhan, komponen solusi, dan pertanyaan penelitian

Masalah	**Kebutuhan**	**Komponen solusi**	**RQ**
M1	KF-04, KF-05, KF-06	Agen pertahanan DDQN yang menyetel parameter setiap *epoch*	RQ2
M2	KF-02, KF-05, KNF-02	Empat parameter insentif dengan *action masking*	RQ1, RQ2
M3	KF-01, KF-03, KF-07, KNF-01	Simulator tervalidasi, agen penyerang yang belajar, kumpulan penyerang, evaluasi tiga rezim	RQ1, RQ3
M4	KF-08, KNF-07	Suku biaya pada Persamaan (II.10) dan pencatatan biaya pertahanan	RQ3

tentu sama dengan jaringan nyata, sebagaimana selisih antara simulasi dan uji fisik pada Wushishi dkk. (2026). Keempat, satu koalisi penyerang tidak mewakili penyerang independen yang saling bersaing. Mitigasi keempat risiko ini dirinci pada Bab V.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before* and *after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.

DAFTAR PUSTAKA

Laneve, C., & Veschetti, A. (2025). A stochastic analysis of the Gasper protocol. *Computer Communications*, *236*, 108123. https : / / doi . org / 10 . 1016 / j . comcom.2025.108123

Rizal, S., & Kim, D.-S. (2025). Enhancing blockchain consensus mechanisms: A comprehensive survey on machine learning applications and optimizations. *Blockchain: Research and Applications*, *6*, 100302. https://doi.org/10.1016/j.bcra.2025.100302

Skowroński, R. (2026). Adaptive threat mitigation in PoW blockchains (Part II): A deep reinforcement learning approach to countering evasive adversaries. *Sensors*, *26*(4), 1368. https://doi.org/10.3390/s26041368

Wushishi, U., Hussain, N., Hussain, A., Al-Rasheed, A., & Ullah, Z. (2026). Co-ADAM: A co-evolutionary signaling game framework for equilibrium cyber deception in industrial IoT. *Scientific Reports*, *16*, 25306. https://doi.org/10.1038/s41598-026-60920-0

LAMPIRAN A

SOURCE CODE

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

Listing A.1 Binary search code

```
% -- Example of pseudocode and source code listing --
% -- Gunakan minipage agar listing tidak terpotong ke halaman
   berikutnya --



\begin{minipage}{\textwidth}
\begin{lstlisting}[caption={Iterative binary search in Python},
   label={lst:binary_iter}, frame=single, captionpos=t, language=
   Python]
def binary_search(arr, target):
    """
    Performs binary search on a sorted array.

    Args:
        arr: A sorted list of elements
        target: The element to search for

    Returns:
        Index of target if found, -1 otherwise
    """
    left = 0
    right = len(arr) - 1

    while left <= right:
        mid = (left + right) // 2

        if arr[mid] == target:
            return mid
        elif arr[mid] < target:
            left = mid + 1
        else:
```

```
            right = mid - 1

    return -1


\end{lstlisting}
\end{minipage}
```

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas