Pertahanan Adaptif pada Konsensus *Proof-of-Stake* Menggunakan *Multi-Agent Reinforcement Learning*

Proposal Tugas Akhir

Oleh

Samuel Chris Michael Bagasta Simanjuntak
18223011



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

2026

LEMBAR PENGESAHAN

Pertahanan Adaptif pada Konsensus *Proof-of-Stake* Menggunakan *Multi-Agent Reinforcement Learning*

Proposal Tugas Akhir

Oleh

Samuel Chris Michael Bagasta Simanjuntak
18223011

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 29 Oktober 2026

Pembimbing

Dr. Ir. Dimitri Mahayana, M.Eng.
NIP. 196808091991021001

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Proposal Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan Proposal Tugas Akhir.
3. Isi proposal ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa dokumen laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 29 Oktober 2026

Samuel Chris Michael Bagasta Simanjuntak
NIM: 18223011

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan Proposal Tugas Akhir ini, saya telah menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu. Berikut adalah rincian penggunaan AI dalam penulisan tesis ini.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II dan Subbab III.2 hal. 34
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	…	…	…
5	Menjelaskan definisi, konsep, gambar, tabel, atau topik tertentu	…	…	…
6	Penyusunan kode program	…	…	…
7	Penyusunan formula atau perhitungan matematis	…	…	…
8	Analisis data	…	…	…
9	Penyusunan kesimpulan atau rekomendasi	…	…	…
10	Lainnya (jelaskan)	…	…	…

Bandung, 29 Oktober 2026

John Doe
NIM: 18299000

DAFTAR ISI

LEMBAR PENGESAHAN iii
PERNYATAAN ORISINALITAS v
PERNYATAAN PENGGUNAAN AI vii
DAFTAR ISI ix
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR PERSAMAAN xv
DAFTAR ALGORITMA xvii
DAFTAR KODE PROGRAM xix
DAFTAR SINGKATAN xxi
DAFTAR SIMBOL xxiii

BAB I PENDAHULUAN **1**
I.1 Latar Belakang 1
I.2 Rumusan Masalah 3
I.3 Tujuan 4
I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah 5
I.5 Hipotesis Tugas Akhir 5
I.6 Metodologi 6
I.7 Sistematika Penulisan 8

BAB II STUDI LITERATUR **9**
II.1 Metode Penelusuran Literatur 9
II.2 Konsensus *Proof-of-Stake* pada *Ethereum* 10
II.2.1 Struktur Waktu dan Pemilihan *Proposer* 10
II.2.2 Pemilihan Rantai Utama dan Finalisasi 10
II.2.3 Insentif: *Reward*, *Slashing*, dan Parameter Finalitas 10
II.3 Serangan Strategis pada Konsensus PoS 11
II.3.1 *Selfish Mining* dan Reorganisasi Rantai 11
II.3.2 Serangan *Balancing* dan *Bouncing* 12
II.3.3 Ambang Kekuatan Penyerang 12
II.3.4 Mitigasi yang Diterapkan Saat Ini 12
II.4 Pendekatan Analisis Keamanan Konsensus 13
II.5 Dasar Teori *Reinforcement Learning* 13
II.5.1 *Markov Decision Process* dan Versi Terbatasnya 13
II.5.2 *Markov Game* untuk Interaksi Penyerang dan Pertahanan . 14
II.5.3 PPO dan MAPPO 15
II.5.4 *Self-Play* dan Pelatihan Berbasis Populasi 16
II.5.5 Metrik Ketangguhan 17
II.5.6 Rancangan Awal Ruang *State*, *Action*, dan *Reward* 17
II.5.7 Batas Perubahan Parameter Konsensus 19
II.6 Penerapan AI pada Konsensus *Blockchain* 20
II.7 Pertahanan Adaptif Berbasis *Reinforcement Learning* 20
II.8 Penelitian Terkait dan Posisi Tugas Akhir 21

II.8.1 Studi Primer Terdekat 21
II.8.2 Perbandingan Penelitian Terkait 22
II.8.3 Celah Penelitian dalam Cakupan Penelusuran 22

BAB III ANALISIS MASALAH 25
III.1 Analisis Kondisi Saat Ini 25
III.2 Analisis Kebutuhan 25
III.2.1 Identifikasi Masalah Pengguna 25
III.2.2 Kebutuhan Fungsional 25
III.2.3 Kebutuhan Nonfungsional 26
III.3 Analisis Pemilihan Solusi 26
III.3.1 Alternatif Solusi 26
III.3.2 Analisis Penentuan Solusi 26

BAB IV DESAIN KONSEP SOLUSI 29

BAB V RENCANA SELANJUTNYA 31

DAFTAR PUSTAKA 33

Lampiran A *SOURCE CODE* 35
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik . . . 35
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak 36

DAFTAR GAMBAR

DAFTAR TABEL

I.1 Ruang lingkup penelitian pada setiap komponen arena MARL . . . 6
I.2 Keterkaitan premis literatur dengan hipotesis tugas akhir 7
I.3 Keterkaitan tahapan metodologi dengan rumusan masalah 8

II.1 Rancangan awal ruang *state*, *action*, dan *reward* kedua agen 18
II.2 Rancangan awal parameter yang dapat disetel agen pertahanan beserta batas perubahannya 19
II.3 Perbandingan penelitian terkait dan bagian yang diadopsi tugas akhir ini 22

DAFTAR PERSAMAAN

II.1 Syarat *checkpoint* menjadi *justified* 10
II.2 Hubungan *reward* dasar dengan *stake* 11
II.3 Fungsi tujuan *Constrained Markov Decision Process* 14
II.4 Definisi *Markov game* 14
II.5 Fungsi objektif PPO 15
II.6 Profit relatif penyerang 17
II.7 Rancangan fungsi *reward* agen pertahanan 17
II.8 Batasan perubahan parameter konsensus 19

DAFTAR ALGORITMA

DAFTAR *LISTING*

A.1 Binary search code 35

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	*Artificial Intelligence*	
CMDP	*Constrained Markov Decision Process*	
CPU	*Central Processing Unit*	
DQN	*Deep Q-Network*	
DRL	*Deep Reinforcement Learning*	
ETH	*Ether*, mata uang kripto jaringan *Ethereum*	
FFG	*Friendly Finality Gadget*	
GPU	*Graphics Processing Unit*	
IIoT	*Industrial Internet of Things*	
LMD-GHOST	*Latest Message Driven Greedy Heaviest Observed Sub-Tree*	
MAPPO	*Multi-Agent Proximal Policy Optimization*	
MARL	*Multi-Agent Reinforcement Learning*	
MDP	*Markov Decision Process*	
MEV	*Maximal Extractable Value*	
PBFT	*Practical Byzantine Fault Tolerance*	
PoS	*Proof-of-Stake*	
PoW	*Proof-of-Work*	
PPO	*Proximal Policy Optimization*	
RL	*Reinforcement Learning*	
ROI	*Return on Investment*	
RQ	*Research Question*	
SLR	*Systematic Literature Review*	

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
$stake_i$	Saldo efektif (*stake*) validator ke-i	
V	Himpunan seluruh validator aktif	
V_c	Himpunan validator yang memilih *checkpoint* c	
$\mathcal{S}$	Ruang *state*	
$\mathcal{A}$	Ruang aksi	
$\mathcal{A}^k$	Ruang aksi agen ke-k	
P	Peluang transisi antar-*state*	
R, R^k	Fungsi *reward* (agen ke-k)	
r_t	*Reward* pada langkah waktu t	
γ	Faktor diskon	
π	Kebijakan (*policy*) agen	
c_i	Biaya kendala ke-i pada CMDP	
d_i	Batas maksimum biaya kendala ke-i	
$\mathcal{G}$	*Markov game*	
$\mathcal{N}$	Himpunan agen	
θ	Parameter jaringan kebijakan	
$r_t(\theta)$	Rasio peluang aksi kebijakan baru terhadap kebijakan lama	
$\hat{A}_t$	Estimasi *advantage* pada langkah t	
ϵ	Batas *clipping* pada PPO	
H_0, H_1	Hipotesis nol dan hipotesis alternatif	
$\mathbb{E}$	Nilai harapan (ekspektasi)	
$\sum$	Operator penjumlahan	
$\propto$	Sebanding dengan	

BAB I

PENDAHULUAN

I.1 Latar Belakang

Ethereum saat ini menggunakan mekanisme konsensus *Proof-of-Stake* (PoS) melalui protokol Gasper. Dalam protokol ini, waktu dibagi menjadi *slot* berdurasi 12 detik, dan setiap 32 *slot* membentuk satu *epoch*. Blok pertama pada setiap *epoch* disebut *checkpoint*. Sebuah *checkpoint* menjadi *justified* jika didukung oleh validator yang memegang minimal dua pertiga total *stake*, lalu menjadi *finalized* jika *checkpoint* berikutnya juga *justified* (Laneve & Veschetti, 2025). Keamanan protokol ini bertumpu pada insentif ekonomi: validator yang jujur menerima imbalan (*reward*), sedangkan validator yang curang dikenai pemotongan *stake* (*slashing*) (Ethereum Foundation, n.d.; Laneve & Veschetti, 2025).

Masalahnya, parameter insentif dan pertahanan tersebut bersifat statis dan diatur secara manual, sedangkan penyerang terus menyesuaikan strateginya. Berbagai ancaman dari validator strategis telah teridentifikasi. Penyerang dapat menahan blok dan *attestation*, lalu melepaskannya pada saat yang tepat untuk menggeser blok validator jujur dari rantai utama. Pola reorganisasi rantai (*reorg*) ini serupa dengan *selfish mining* pada PoW. Ancaman lain mencakup serangan *balancing* dan *bouncing* yang menghambat finalisasi, penyensoran transaksi (*transaction censorship*), dan eksploitasi *Maximal Extractable Value* (MEV) melalui pengaturan urutan transaksi (Ethereum Foundation, n.d.; Laneve & Veschetti, 2025). Beberapa di antaranya bahkan dapat dilakukan dengan porsi *stake* yang kecil (Ethereum Foundation, n.d.). Respons terhadap ancaman tersebut umumnya berupa tambalan manual. Contohnya, serangan *balancing* diredam dengan *proposer boost* berbobot tetap, sedangkan tambalan untuk serangan *bouncing* justru dihapus kemudian (Laneve & Veschetti, 2025). Mekanisme *proposer boost* pun hanya efektif terhadap *reorg* murah oleh penyerang ber-*stake* kecil dan dapat dimanfaatkan oleh pemegang *stake* besar (Ethereum Foundation, n.d.).

Persoalan ini mendesak karena berdampak langsung pada dua sifat utama jaring-

an, yaitu *safety* (transaksi yang sudah final tidak boleh dibatalkan) dan *liveness* (jaringan harus terus memproses transaksi baru). Analisis stokastik terhadap Gasper menunjukkan bahwa serangan *balancing* dan *bouncing* dapat menggagalkan finalisasi. Bahkan tanpa serangan, kenaikan latensi jaringan hingga sekitar 38 detik sudah membuat *checkpoint* tidak dapat dipastikan *justified* dalam sembilan *epoch* (Laneve & Veschetti, 2025). Jika pertahanan tidak pernah dievaluasi ulang, ada dua risiko yang muncul: transaksi yang sudah final dapat dibatalkan melalui manipulasi rantai, dan jaringan dapat macet sehingga transaksi baru tertahan. Nilai yang dipertaruhkan pun sangat besar. Biaya untuk menguasai lebih dari separuh total *stake Ethereum* diperkirakan hampir 19 miliar dolar AS, dan pada tingkat itu penyerang sudah mampu menyensor transaksi serta mengatur ulang blok sesuai kepentingannya (Ethereum Foundation, n.d.). Karena itu, kedua risiko di atas merupakan ancaman nyata terhadap kepercayaan publik pada *blockchain* sebagai infrastruktur keuangan.

Literatur telah menawarkan beberapa pendekatan untuk menganalisis dan meredam serangan pada mekanisme insentif. Pendekatan formal memodelkan Gasper sebagai proses stokastik dan mengujinya dengan *probabilistic model checker* PRISM+ pada berbagai latensi, jumlah validator, dan skenario serangan (Laneve & Veschetti, 2025). Kecerdasan artifisial juga mulai dimanfaatkan: survei penerapan *machine learning* pada konsensus *blockchain* memetakan penggunaannya untuk prediksi perilaku jaringan, deteksi anomali, dan konsensus adaptif (Rizal & Kim, 2025). Dari sisi penyerang, agen *reinforcement learning* (RL) terbukti mampu mempelajari sendiri tindakan serangan yang paling merusak tanpa perlu dirancang secara manual (Wushishi dkk. 2026). Di sisi pertahanan, agen *Deep Reinforcement Learning* (DRL) yang menyetel parameter deteksi secara dinamis mampu menjaga serangan pada *blockchain* tetap merugi, sedangkan pertahanan statis akhirnya ditembus oleh penyerang yang beradaptasi (Skowroński, 2026). Pada ranah yang lebih luas, *Multi-Agent Reinforcement Learning* (MARL) berbasis pelatihan terpusat dan eksekusi terdesentralisasi, seperti MAPPO, telah menjadi pendekatan utama untuk pengambilan keputusan banyak agen dalam lingkungan yang berubah-ubah (Ma dkk. 2025). Pelatihan ko-evolusioner yang mempertemukan agen pertahanan dengan kumpulan penyerang adaptif juga terbukti menghasilkan pertahanan yang lebih tangguh (Wushishi dkk. 2026).

Meskipun demikian, masih ada celah penelitian. Analisis formal (Laneve & Veschetti, 2025) memang mengukur dampak serangan secara kuantitatif, tetapi perilaku penyerangnya ditetapkan sejak awal (*scripted*) dan parameter protokol diubah secara manual, sehingga analisis harus diulang untuk setiap varian serangan baru. Pertahan-

an DRL pada Skowroński (2026) sudah adaptif, tetapi diterapkan pada PoW, hanya menyetel ambang deteksi, dan menghadapi penyerang yang beradaptasi secara heuristik, bukan penyerang yang ikut belajar. Pelatihan ko-evolusioner pada Wushishi dkk. (2026) sudah melatih penyerang dan pertahanan bersamaan, tetapi diterapkan pada *Industrial Internet of Things*, bukan pada konsensus *blockchain*. MAPPO pada Ma dkk. (2025) juga masih digunakan untuk agen-agen yang bekerja sama, bukan agen yang saling berlawanan. Survei Rizal dan Kim (2025) turut menunjukkan bahwa pemanfaatan AI pada konsensus masih didominasi prediksi dan deteksi pasif, sedangkan *blockchain* yang menyesuaikan parameternya sendiri masih menjadi arah riset ke depan. Dengan kata lain, belum ada penelitian yang melatih agen penyerang dan agen pertahanan secara bersamaan untuk menyetel parameter insentif pada protokol Gasper. Celah inilah yang mendasari tugas akhir ini, yaitu membangun arena penyerang-pertahanan pada konsensus PoS di mana agen pertahanan ikut belajar mengatur *reward* dan *slashing* secara adaptif menggunakan MARL.

I.2 Rumusan Masalah

Pokok persoalan tugas akhir ini adalah cara mengevaluasi ketahanan protokol PoS terhadap serangan yang terus beradaptasi. Selama ini, ketahanan Gasper dinilai terhadap pola serangan yang ditetapkan sejak awal, sementara parameter pertahanannya dibiarkan tetap atau hanya ditambal secara manual setelah serangan ditemukan (Laneve & Veschetti, 2025). Akibatnya, kesimpulan bahwa suatu parameter sudah "aman" bisa menyesatkan, karena kesimpulan itu hanya berlaku untuk pola serangan yang diuji saat itu. Jika penyerang diberi kesempatan beradaptasi lebih jauh, tidak ada jaminan parameter yang sama masih efektif. Gejala ini sudah teramati pada *blockchain* PoW: pertahanan statis yang awalnya membuat serangan merugi (-95%) ditembus oleh penyerang adaptif setelah sekitar 20 hari, sehingga profit rata-rata penyerang selama 30 hari kembali positif ($+65\%$) (Skowroński, 2026).

Masalah ini penting diselesaikan karena kesalahan menilai ketahanan protokol dapat berujung pada kerugian finansial nyata bagi validator jujur dan pengguna, serta mengancam *safety* dan *liveness* jaringan secara keseluruhan.

Sebagai solusi, tugas akhir ini memodelkan interaksi penyerang dan pertahanan pada konsensus PoS sebagai permainan multi-agen yang dilatih bersamaan melalui skema *self-play* dengan MARL. Dengan cara ini, kedua pihak sama-sama diberi kesempatan beradaptasi sebelum ketahanan kebijakan pertahanan dinilai. Evaluasi pun bergeser dari pengujian terhadap parameter statis menjadi pengujian terhadap penyerang yang adaptif.

Rumusan masalah tersebut dijabarkan menjadi tiga pertanyaan penelitian (*Research Questions*/RQ) berikut:

- **RQ1:** Sejauh mana formulasi *Markov game* (ruang *state*, *action*, dan *reward*) valid dan memadai untuk merepresentasikan dinamika adaptasi penyerang dan pertahanan pada konsensus PoS tanpa melanggar spesifikasi dasar protokol?
- **RQ2:** Apakah kebijakan pertahanan hasil pelatihan MARL dengan *self-play* lebih tangguh (*robust*) terhadap penyerang adaptif dibandingkan parameter pertahanan statis?
- **RQ3:** Bagaimana karakteristik strategi serangan yang ditemukan secara otomatis oleh agen RL, dan seberapa efektif pertahanan adaptif menekan profit relatif penyerang serta tingkat pelanggaran *safety* dan *liveness*?

I.3 Tujuan

Berdasarkan rumusan masalah di atas, tugas akhir ini bertujuan untuk:

1. Merancang dan mengimplementasikan simulator konsensus PoS yang mengacu pada protokol Gasper dan dikalibrasi dengan data *on-chain Ethereum*, serta merumuskan interaksi penyerang dan pertahanan di dalamnya sebagai *Markov game*.
2. Melatih agen pertahanan menggunakan MAPPO dengan skema *self-play* dan *population-based training* agar mampu menyesuaikan parameter *reward*, *slashing*, dan finalitas *checkpoint*, lalu membandingkan ketahanannya dengan pertahanan statis pada populasi penyerang adaptif yang sama.
3. Menganalisis pola strategi yang muncul dari kedua agen, serta mengukur dampaknya terhadap tingkat pelanggaran *safety* dan *liveness*, profit relatif penyerang, dan biaya pertahanan berupa *reward* yang hilang dari validator jujur.

Tugas akhir ini dinyatakan berhasil jika memenuhi dua kriteria. Pertama, simulator mampu mereproduksi perilaku jaringan dalam kondisi normal (tanpa serangan) yang selaras secara statistik dengan data *on-chain*. Kriteria ini sekaligus menjawab keterbatasan studi sebelumnya yang hanya dapat memvalidasi model Gasper terhadap protokol pendahulunya karena belum ada *benchmark* (Laneve & Veschetti, 2025). Kedua, kebijakan pertahanan hasil MARL menunjukkan penurunan terukur pada profit relatif penyerang atau tingkat pelanggaran *safety*/*liveness* dibanding pertahanan statis, ketika diuji melawan populasi penyerang yang tidak pernah dilihat selama pelatihan. Profit relatif dihitung terhadap pendapatan yang seharusnya diperoleh penyerang jika bertindak jujur, mengikuti definisi pada Skowroński (2026).

I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah

Agar tugas akhir ini dapat diselesaikan dalam dua semester, ditetapkan batasan berikut:

1. Protokol yang dimodelkan hanya Gasper (LMD-GHOST + Casper FFG) yang digunakan *Ethereum*. Protokol PoS lain seperti *Tendermint* atau *Ouroboros* tidak dibahas karena aturan *fork-choice* dan finalitasnya berbeda.
2. Serangan yang dimodelkan dibatasi pada tiga kategori dari Subbab I.1: perilaku sejenis *selfish mining*, reorganisasi rantai (*reorg*/*balancing attack*), dan *censorship* terhadap *attestation* atau proposal. *Long-range attack* dan MEV tidak dimasukkan karena membutuhkan model dan skala simulasi yang berbeda. Serangan *bouncing* juga tidak dimodelkan khusus karena sulit direproduksi pada Gasper saat ini, sedangkan *time attack* bergantung pada manipulasi sinkronisasi jam yang berada di luar model level *slot* (Laneve & Veschetti, 2025).
3. Aksi agen pertahanan dibatasi pada tiga parameter insentif, yaitu laju *reward per epoch*, tingkat atau ambang *slashing*, dan parameter finalitas *checkpoint*. Perubahan struktur algoritma protokol, misalnya aturan *fork-choice*, berada di luar lingkup.
4. Simulator berupa model ringan pada level *slot* dan *epoch*, bukan *node Ethereum* lengkap, dan tidak dijalankan di *testnet* maupun *mainnet*. Penyederhanaan seperti memperlakukan blok sebagai kotak hitam dan mengabaikan pembagian komite telah terbukti memadai untuk menganalisis konsensus Gasper (Laneve & Veschetti, 2025). Asumsi ini diambil karena sumber daya komputasi terbatas pada CPU *multi-core* dan GPU kelas menengah.
5. Skala jaringan dibatasi ratusan sampai seribu validator. Studi sebelumnya melaporkan bahwa hasil analisis justifikasi dan finalisasi Gasper sudah stabil pada jaringan berukuran belasan validator (Laneve & Veschetti, 2025).
6. Kalibrasi simulator mengacu pada data *on-chain* publik (*BigQuery* dan *beaconcha.in*) serta spesifikasi resmi *consensus-specs*. Data historis tersebut diasumsikan cukup mewakili perilaku jaringan secara umum.

Ringkasan ruang lingkup disajikan pada Tabel I.1.

I.5 Hipotesis Tugas Akhir

Hipotesis tugas akhir ini disusun dari empat premis literatur. Pertama, Laneve dan Veschetti (2025) menunjukkan bahwa Gasper dengan parameter tetap dapat digagalkan finalisasinya oleh serangan *balancing* dan *bouncing*, dan mitigasinya masih berupa tambalan manual. Kedua, Skowroński (2026) membuktikan pada domain

Tabel I.1 Ruang lingkup penelitian pada setiap komponen arena MARL

Komponen	**Termasuk Ruang Lingkup**	**Di Luar Ruang Lingkup**
Protokol	Gasper (LMD-GHOST + Casper FFG)	Tendermint, Ouroboros, protokol PoS lain
Jenis serangan	*Selfish mining*, *reorg*/*balancing*, *censorship*	*Long-range*, MEV, *bouncing*, *time attack*
Aksi pertahanan	*Reward rate*, *slashing*, finalitas *checkpoint*	Perubahan aturan *fork-choice*
Simulator	Model ringan level *slot*/*epoch*	*Full node*, *testnet*, *mainnet*
Skala jaringan	Ratusan sampai seribu validator	Skala *mainnet* (ratusan ribu validator)
Kalibrasi data	BigQuery, beaconcha.in, *consensus-specs*	Data *proprietary* atau non-publik

blockchain bahwa pertahanan DRL yang menyetel parameternya sendiri mampu menjaga serangan tetap merugi (-42%), sedangkan pertahanan statis akhirnya ditembus ($+65\%$). Ketiga, Wushishi dkk. (2026) menunjukkan bahwa pertahanan yang dilatih secara ko-evolusioner melawan kumpulan penyerang adaptif lebih tangguh dibanding pertahanan yang dilatih melawan penyerang tetap. Keempat, Ma dkk. (2025) menunjukkan bahwa MAPPO dengan pelatihan terpusat mampu menghasilkan kebijakan multi-agen yang stabil dalam kondisi yang terus berubah, sehingga layak dipakai untuk melatih kedua agen. Dari premis tersebut, dirumuskan hipotesis berikut:

- H_0: Tidak ada perbedaan signifikan pada metrik keamanan (tingkat pelanggaran *safety*/*liveness* dan profit relatif penyerang) antara pertahanan hasil MARL *self-play* dan pertahanan statis, ketika keduanya diuji melawan populasi penyerang adaptif yang sama.
- H_1: Pertahanan hasil MARL *self-play* menghasilkan tingkat pelanggaran *safety*/*liveness* dan profit relatif penyerang yang lebih rendah secara signifikan dibanding pertahanan statis. Penurunan ini diperkirakan disertai kenaikan biaya pertahanan berupa berkurangnya *reward* validator jujur, yang dianalisis sebagai *trade-off*.

Keterkaitan premis dan hipotesis dirangkum pada Tabel I.2.

I.6 Metodologi

Tugas akhir ini menggunakan pendekatan eksperimen simulasi kuantitatif dengan tahapan berikut:

1. **Investigasi dan perumusan masalah.** Menelusuri kondisi keamanan konsensus PoS, lalu melakukan *systematic literature review* (SLR) di Scopus

Tabel I.2 Keterkaitan premis literatur dengan hipotesis tugas akhir

Premis	**Temuan Literatur**	**Kaitan dengan Hipotesis**
Premis 1	Laneve & Veschetti (2025): Gasper dengan parameter tetap rentan terhadap serangan finalisasi; mitigasi masih manual	Mendasari H_0 sebagai kondisi awal yang diuji
Premis 2	Skowroński (2026): pertahanan DRL adaptif mengalahkan pertahanan statis pada *blockchain*	Bukti empiris H_1 di domain *blockchain*
Premis 3	Wushishi dkk. (2026): pertahanan koevolusioner lebih tangguh terhadap penyerang adaptif	Bukti empiris H_1 untuk skema pelatihan dua sisi
Premis 4	Ma dkk. (2025): MAPPO menghasilkan kebijakan multi-agen yang stabil dalam kondisi dinamis	Dasar kelayakan metode untuk menguji H_1
Gabungan	Pertahanan adaptif vs. statis pada populasi penyerang adaptif yang sama	Menjawab RQ2 dan RQ3

dengan *query*: `TITLE-ABS-KEY(("proof of stake" OR blockchain OR consensus) AND "reinforcement learning" AND (attack OR defense OR security OR "selfish mining"))`. Hasilnya disajikan pada Bab II.

2. **Perancangan simulator dan formulasi permainan.** Membangun simulator PoS level *slot*/*epoch* (pemilihan *proposer* dan komite, *fork-choice*, *reward*, *slashing*) dengan struktur modul mengacu pada Laneve dan Veschetti (2025), lalu merumuskan *state*, *action*, dan *reward* kedua agen sebagai *Markov game* untuk menjawab RQ1.
3. **Validasi simulator.** Membandingkan keluaran simulator dalam kondisi normal dengan statistik jaringan *Ethereum* sungguhan, misalnya peluang justifikasi, finalisasi, dan *fork*. Simulator dipakai untuk tahap berikutnya hanya jika selisihnya dalam batas yang dapat diterima.
4. **Reproduksi *baseline* serangan.** Melatih agen penyerang RL tunggal melawan pertahanan statis sebagai titik pembanding, untuk menunjukkan seberapa jauh penyerang yang belajar dapat mengeksploitasi parameter tetap.
5. **Pembangunan arena MARL.** Membangun lingkungan multi-agen dengan PettingZoo dan RLlib, lalu melatih kedua agen bergantian menggunakan MAPPO (Ma dkk. 2025) dengan *self-play*, dilanjutkan *population-based training* dengan beberapa varian penyerang. Kumpulan kebijakan penyerang historis dipakai agar agen pertahanan tidak *overfit* pada satu lawan (Wushishi dkk. 2026). Aksi pertahanan dibatasi dengan *action masking* agar tidak melanggar batas *liveness* dan keadilan bagi validator jujur (Skowroński, 2026).

6. **Eksperimen dan evaluasi.** Menguji pertahanan MARL dan pertahanan statis melawan populasi penyerang adaptif yang sama untuk menguji H_0 dan H_1. Pengujian dilakukan pada tiga jenis penyerang, yaitu acak, adaptif selama pengujian, dan dilatih khusus untuk melawan masing-masing pertahanan (Wushishi dkk. 2026), serta diulang dengan beberapa *seed* acak untuk uji signifikansi. Metrik yang diukur adalah tingkat pelanggaran *safety* dan *liveness*, profit relatif penyerang, biaya pertahanan, dan skor *robustness*.
7. **Analisis dan kesimpulan.** Menganalisis pola strategi kedua agen, mengaitkannya dengan RQ dan hipotesis, lalu menyusun kesimpulan dan saran, termasuk perluasan ke *long-range attack* dan MEV.

Keterkaitan tahapan dengan rumusan masalah dirangkum pada Tabel I.3.

Tabel I.3 Keterkaitan tahapan metodologi dengan rumusan masalah

No.	Tahapan	Menjawab	Keluaran Utama
1	Investigasi dan perumusan masalah	Latar Belakang	Peta literatur dan posisi kontribusi (Bab II)
2	Perancangan simulator dan formulasi permainan	RQ1	Simulator Gasper, formulasi *Markov game*
3	Validasi simulator	Kriteria 1	Simulator tervalidasi terhadap data *on-chain*
4	Reproduksi *baseline* serangan	Konteks H_0	Agen penyerang tunggal
5	Pembangunan arena MARL	RQ1, RQ2	Kebijakan pertahanan hasil *self-play*
6	Eksperimen dan evaluasi	RQ2, RQ3, H_0/H_1	Metrik *safety*, *liveness*, profit, *robustness*
7	Analisis dan kesimpulan	Seluruh RQ	Simpulan dan saran

I.7 Sistematika Penulisan

Laporan ini disusun sebagai berikut:

1. **Bab I Pendahuluan:** latar belakang, rumusan masalah, tujuan, ruang lingkup, hipotesis, metodologi, dan sistematika penulisan.
2. **Bab II Studi Literatur:** dasar teori konsensus Gasper, serangan strategis pada PoS, *reinforcement learning* dan *Markov game*, penelitian terkait, serta celah penelitian.
3. **Bab III Analisis Masalah:** analisis kelemahan pertahanan PoS statis, formulasi *Markov game*, dan rancangan pendekatan MARL *self-play*.
4. **Bab IV Desain Konsep Solusi:** rancangan arsitektur simulator, ruang *state*, *action*, dan *reward*, serta alur *population-based training*.
5. **Bab V Rencana Selanjutnya:** langkah implementasi, rancangan eksperimen statis versus MARL, metrik evaluasi, serta analisis risiko dan mitigasinya.

BAB II

STUDI LITERATUR

Bab ini menyajikan landasan bagi rumusan masalah dan pertanyaan penelitian pada Subbab I.2. Pembahasan disusun dari kasus yang dikaji menuju teori dan penelitian terdahulu. Pertama, dijelaskan cara kerja konsensus Gasper dan serangan yang mengancamnya, sebagai kasus yang dikaji. Kedua, dijelaskan teori *reinforcement learning* yang menjadi dasar solusi, lengkap dengan asumsi, keterbatasan, serta rancangan awal ruang agen dan batas perubahan parameter. Terakhir, penelitian terdahulu dibandingkan untuk menunjukkan posisi tugas akhir ini dan celah yang diisinya.

II.1 Metode Penelusuran Literatur

Literatur dikumpulkan melalui *systematic literature review* (SLR) di basis data Scopus menggunakan *query* yang tercantum pada Bab I. Literatur dipilih jika (1) terbit di jurnal bereputasi kuartil pertama (Q1) pada tahun 2025 atau sesudahnya, (2) membahas keamanan konsensus *blockchain*, penerapan *reinforcement learning* pada keamanan, atau keduanya, dan (3) menyajikan hasil empiris atau formal yang dapat diverifikasi. Dokumentasi resmi *Ethereum* digunakan sebagai rujukan pelengkap untuk definisi teknis protokol. Hasil penelusuran dikelompokkan ke dalam empat klaster: (a) mekanisme dan analisis konsensus Gasper, (b) serangan strategis pada konsensus, (c) penerapan AI pada konsensus *blockchain*, dan (d) pertahanan adaptif berbasis RL.

Kriteria ini sengaja dibuat ketat agar setiap klaim bertumpu pada sumber yang terverifikasi. Konsekuensinya, karya yang terbit di prosiding, pracetak, atau jurnal di luar Q1 tidak ikut disintesis. Karena itu, kesimpulan tentang celah penelitian pada Subbab II.8 hanya berlaku dalam cakupan penelusuran ini.

II.2 Konsensus *Proof-of-Stake* pada *Ethereum*

II.2.1 Struktur Waktu dan Pemilihan *Proposer*

Gasper membagi waktu ke dalam *slot* berdurasi 12 detik. Pada setiap *slot*, satu validator dipilih secara acak semu melalui mekanisme RANDAO untuk mengusulkan blok baru. Sebanyak 32 *slot* berurutan membentuk satu *epoch*, dan blok pertama setiap *epoch* disebut *checkpoint* (Laneve & Veschetti, 2025). Untuk menjadi validator, pengguna harus menyetorkan 32 ETH sebagai *stake* (Ethereum Foundation, n.d.). Jika *proposer* sedang tidak aktif, *slot* tersebut berlalu tanpa blok. Sebaliknya, keterlambatan jaringan dapat membuat beberapa blok diterima pada ketinggian yang sama sehingga terjadi percabangan (*fork*).

II.2.2 Pemilihan Rantai Utama dan Finalisasi

Gasper menggabungkan dua komponen. Komponen pertama, LMD-GHOST, menentukan rantai utama ketika terjadi *fork* dengan mengambil suara terbaru setiap validator lalu memilih cabang yang memiliki bobot dukungan terbesar. Komponen kedua, Casper FFG, memberikan finalitas melalui dua tahap (Laneve & Veschetti, 2025). Sebuah *checkpoint* c menjadi *justified* jika total *stake* validator yang memilihnya mencapai minimal dua pertiga total *stake*:

$$\sum_{i \in V_c} \mathit{stake}_i \geq \frac{2}{3} \sum_{j \in V} \mathit{stake}_j \tag{II.1}$$

dengan V_c adalah himpunan validator yang memilih c dan V adalah seluruh validator aktif. Sebuah *checkpoint* menjadi *finalized* jika *checkpoint* itu sendiri dan *checkpoint* berikutnya sama-sama *justified*. Blok yang sudah *finalized* hanya dapat dibatalkan jika penyerang rela kehilangan lebih dari sepertiga total *stake*. Jaminan ini disebut finalitas ekonomi dan menjadi dasar *safety* protokol (Ethereum Foundation, n.d.). Sementara itu, *liveness* terjaga jika *checkpoint* baru terus berhasil difinalisasi. Dalam kondisi normal dengan latensi jaringan sekitar 12,6 detik, peluang finalisasi sebuah *checkpoint* dalam 96 *slot* (tiga *epoch*) hampir mencapai 1 (Laneve & Veschetti, 2025).

II.2.3 Insentif: *Reward*, *Slashing*, dan Parameter Finalitas

Validator memperoleh *reward* dengan mengusulkan blok dan memberikan suara (*attestation*) yang sejalan dengan mayoritas. Besar *reward* dasar validator i sebanding dengan saldo efektifnya dan berbanding terbalik dengan akar total *stake* jaringan

(Laneve & Veschetti, 2025):

$$base_reward_i \propto \frac{stake_i}{\sqrt{\sum_{j \in V} stake_j}} \tag{II.2}$$

Saldo efektif dibatasi maksimal 32 ETH. Sebaliknya, validator yang mengusulkan dua blok berbeda pada *slot* yang sama atau memberikan suara ganda pada *checkpoint* akan terkena *slashing*. Sebanyak 1/32 saldonya langsung dihanguskan, ia dikeluarkan dari jaringan selama 36 hari, dan selama masa itu masih dikenai penalti tambahan (Laneve & Veschetti, 2025).

Selain *reward* dan *slashing*, ada dua aturan yang secara langsung memengaruhi finalitas. Aturan pertama adalah batas waktu inklusi *attestation*. Suara hanya diterima jika masuk dalam 32 *slot*, dan suara yang terlambat melewati batas ini dikenai penalti (Laneve & Veschetti, 2025). Aturan kedua adalah *inactivity leak*. Validator yang tidak memberikan suara kehilangan *stake* secara bertahap sampai porsi mereka di bawah sepertiga, sehingga finalisasi dapat berjalan kembali (Ethereum Foundation, n.d.). Kedua aturan inilah yang dimaksud dengan "parameter finalitas *checkpoint*" pada Bab I. Bersama besaran *reward* dan tingkat *slashing*, keduanya menjadi parameter yang akan disetel oleh agen pertahanan.

II.3 Serangan Strategis pada Konsensus PoS

Serangan strategis adalah serangan oleh validator yang secara rasional menyimpang dari protokol untuk mendapatkan keuntungan lebih besar atau merusak jaringan. Pada dasarnya, serangan dengan *stake* kecil merupakan variasi dari dua perilaku: terlalu pasif (tidak atau terlambat memberikan suara dan blok) atau terlalu aktif (mengirim suara atau blok lebih dari sekali dalam satu *slot*) (Ethereum Foundation, n.d.). Berikut jenis serangan yang relevan dengan tugas akhir ini.

II.3.1 *Selfish Mining* dan Reorganisasi Rantai

Selfish mining adalah serangan penambangan strategis pada PoW: penambang menahan blok yang ia temukan, lalu melepaskannya pada saat yang tepat agar blok milik penambang jujur terbuang. Serangan ini sudah lama menjadi sasaran pengembangan pertahanan, termasuk pertahanan berbasis AI (Skowroński, 2026). Pada PoS, pola serupa muncul sebagai reorganisasi rantai (*reorg*). Validator penyerang membuat blok tetapi tidak menyebarkannya, lalu melepaskan blok beserta suaranya tepat ketika validator jujur mengusulkan blok berikutnya. Akibatnya, aturan *fork-choice* menganggap cabang penyerang lebih berat dan blok jujur tergeser. Se-

rangan ini awalnya diperkirakan membutuhkan sekitar 30% *stake*, tetapi kemudian terbukti dapat dilakukan dengan porsi yang jauh lebih kecil (Ethereum Foundation, n.d.). *Reorg* dapat dimanfaatkan untuk menyensor transaksi tertentu (*censorship*) atau mengambil nilai dari urutan transaksi (MEV) (Ethereum Foundation, n.d.).

II.3.2 Serangan *Balancing* dan *Bouncing*

Serangan *balancing* memecah suara validator jujur ke dua cabang secara seimbang sehingga tidak ada cabang yang mencapai dua pertiga suara dan finalisasi terhenti. Serangan *bouncing* membuat justifikasi berpindah-pindah antara dua cabang sehingga dua *checkpoint* berturutan pada cabang yang sama tidak pernah tercapai (Ethereum Foundation, n.d.). Laneve dan Veschetti (2025) menunjukkan bahwa dengan 4 dari 13 validator yang tidak jujur, serangan *balancing* mampu mencegah finalisasi, dan serangan *bouncing* membuat peluang finalisasi turun menjadi nol.

II.3.3 Ambang Kekuatan Penyerang

Dampak serangan meningkat seiring porsi *stake* yang dikuasai penyerang. Dengan sepertiga *stake*, penyerang dapat menunda finalisasi cukup dengan berhenti memberikan suara, sehingga mengganggu *liveness*. Dengan 34% *stake*, penyerang berpotensi membuat dua cabang sama-sama final, sehingga melanggar *safety*. Dengan lebih dari separuh *stake*, penyerang dapat menyensor transaksi dan mengatur blok-blok berikutnya. Dengan dua pertiga *stake*, penyerang dapat memfinalisasi rantai pilihannya dan mengubah riwayat (Ethereum Foundation, n.d.). Tugas akhir ini berfokus pada penyerang dengan *stake* di bawah sepertiga, yaitu wilayah di mana serangan bergantung pada strategi yang cerdik, bukan pada kekuatan suara semata, dan di mana parameter insentif paling menentukan.

II.3.4 Mitigasi yang Diterapkan Saat Ini

Mitigasi yang ada umumnya berupa tambalan protokol yang dirancang manual. Serangan *balancing* diredam dengan *proposer boost*, yaitu tambahan bobot tetap bagi blok yang tiba tepat waktu. Pada simulasi Laneve dan Veschetti (2025), *boost* sebesar 40% membuat peluang finalisasi kembali mencapai 1 setelah 3 *epoch*. Namun, mekanisme ini hanya efektif terhadap *reorg* murah, dan penyerang dengan sekitar 7% *stake* justru dapat memanfaatkannya untuk menggeser blok jujur (Ethereum Foundation, n.d.). Tambalan untuk serangan *bouncing* bahkan telah dihapus dari protokol (Laneve & Veschetti, 2025). Pola ini menunjukkan bahwa pertahanan saat ini bersifat reaktif: parameter ditetapkan sekali, lalu diubah manual setelah serangan baru ditemukan.

II.4 Pendekatan Analisis Keamanan Konsensus

Terdapat tiga pendekatan utama untuk menilai ketahanan konsensus terhadap serangan.

Analisis formal stokastik. Laneve dan Veschetti (2025) memodelkan Gasper sebagai kumpulan proses (validator, jaringan, pengelola suara, dan pemilih *proposer*) dalam PRISM+, lalu menghitung peluang justifikasi dan finalisasi pada berbagai latensi jaringan. Hasilnya antara lain peluang justifikasi dalam 64 *slot* sebesar 0,552 dan lebih dari 0,9 dalam 96 *slot*, serta penurunan tajam peluang finalisasi saat latensi naik. Kelemahannya, perilaku penyerang ditentukan sejak awal dan parameter diubah secara manual.

Analisis berbasis *machine learning*. Survei Rizal dan Kim (2025) menunjukkan bahwa *machine learning* banyak dipakai untuk memprediksi perilaku jaringan dan mendeteksi serangan pada konsensus *blockchain*. Pendekatan ini membantu mengenali ancaman, tetapi umumnya tidak mengubah aturan protokol.

Penyerang yang belajar. Agen penyerang dapat dimodelkan sebagai agen RL yang belajar sendiri strategi paling menguntungkan. Pada Wushishi dkk. (2026), agen penyerang berbasis *Q-learning* secara mandiri belajar lebih sering memilih aksi berdampak tinggi dengan intensitas tertinggi, tanpa diarahkan secara manual. Pendekatan ini mampu menemukan kelemahan yang tidak terpikirkan oleh perancang, tetapi hasilnya hanya bermakna jika pertahanan juga diberi kesempatan beradaptasi.

Ketiga pendekatan ini saling melengkapi. Analisis formal memberikan acuan perilaku normal Gasper yang dapat dipakai untuk memvalidasi simulator. *Machine learning* memberikan cara membaca sinyal ancaman dari data jaringan. Penyerang yang belajar memberikan cara menguji pertahanan secara lebih keras. Tugas akhir ini menggabungkan ketiganya: simulator divalidasi terhadap perilaku normal, sinyal jaringan dijadikan pengamatan agen, dan pertahanan diuji melawan penyerang yang belajar.

II.5 Dasar Teori *Reinforcement Learning*

II.5.1 *Markov Decision Process* dan Versi Terbatasnya

Reinforcement learning (RL) adalah metode pembelajaran di mana agen belajar mengambil keputusan dengan mencoba aksi dan menerima umpan balik berupa *reward*. Masalah ini dimodelkan sebagai *Markov Decision Process* (MDP) $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, yaitu ruang *state*, ruang aksi, peluang transisi, fungsi *reward*, dan faktor diskon. Tu-

juan agen adalah menemukan kebijakan π yang memaksimalkan total *reward* jangka panjang.

Pada sistem kritis seperti konsensus, agen tidak boleh mengejar *reward* dengan mengorbankan keselamatan jaringan. Karena itu digunakan *Constrained* MDP (CMDP), yang menambahkan batasan pada biaya tertentu (Skowroński, 2026):

$$\max_{\pi} \ \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t r_t\right] \quad \text{dengan syarat} \quad \mathbb{E}_{\pi}[c_i] \leq d_i, \ \ \forall i \tag{II.3}$$

dengan c_i adalah biaya seperti tingkat salah tuduh terhadap validator jujur atau keterlambatan blok, dan d_i adalah batas yang diizinkan. Dalam praktiknya, batasan ini dapat ditegakkan melalui *action masking*, yaitu menonaktifkan aksi yang akan melanggar batas sebelum agen memilih (Skowroński, 2026).

II.5.2 *Markov Game* untuk Interaksi Penyerang dan Pertahanan

Ketika lebih dari satu agen belajar dalam lingkungan yang sama, MDP diperluas menjadi *Markov game*. Setiap agen memiliki ruang aksi dan fungsi *reward* masing-masing, sedangkan *state* dan transisinya dipengaruhi oleh aksi semua agen sekaligus. Wushishi dkk. (2026) menggunakan bentuk ini untuk memodelkan interaksi agen pertahanan dan agen penyerang, dengan ruang aksi dan *reward* yang terpisah untuk masing-masing pihak serta batasan anggaran pertahanan:

$$\mathcal{G} = \left(\mathcal{N}, \mathcal{S}, \{\mathcal{A}^k\}_{k\in\mathcal{N}}, P, \{R^k\}_{k\in\mathcal{N}}, \gamma\right) \tag{II.4}$$

dengan $\mathcal{N}$ adalah himpunan agen, sedangkan $\mathcal{A}^k$ dan R^k adalah ruang aksi dan fungsi *reward* agen ke-k. Pada tugas akhir ini $\mathcal{N}$ terdiri atas dua agen: penyerang ($k = a$), yang *reward*-nya berasal dari keuntungan berlebih, dan pertahanan ($k = d$), yang *reward*-nya berasal dari terjaganya *safety*, *liveness*, dan rendahnya profit penyerang. Karena kepentingan keduanya berlawanan, setiap perubahan kebijakan satu agen langsung mengubah lingkungan bagi agen lainnya.

Asumsi. Formulasi ini bertumpu pada empat asumsi.

1. Seluruh validator penyerang bertindak sebagai satu koalisi terkoordinasi dengan total *stake* di bawah sepertiga, sesuai fokus pada Subbab II.3.3.
2. Validator jujur mengikuti protokol secara tetap, seperti pada model Gasper

Laneve dan Veschetti (2025), sehingga satu-satunya sumber adaptasi adalah kedua agen.

3. Agen pertahanan berperan sebagai lapisan tata kelola protokol. Ia hanya melihat statistik agregat jaringan dan tidak mengetahui identitas penyerang, kecuali ketika terjadi pelanggaran yang dapat dikenai *slashing*. Dengan demikian, permainan ini teramati sebagian.
4. Sifat Markov dipenuhi dengan memasukkan ringkasan jendela waktu terakhir ke dalam *state*, seperti penggunaan jendela geser pada Skowroński (2026).

Keterbatasan. Asumsi tersebut membawa tiga keterbatasan.

1. Satu koalisi tidak mewakili kondisi di mana beberapa penyerang independen bersaing satu sama lain.
2. Permainan ini bukan permainan jumlah nol (*zero-sum*), karena pertahanan juga menanggung biaya berupa *reward* validator jujur yang hilang. Akibatnya, titik keseimbangan tidak dijamin tunggal.
3. Latensi jaringan dimodelkan dengan laju rata-rata, seperti pada Laneve dan Veschetti (2025), sehingga keterlambatan ekstrem yang jarang terjadi dapat terlewat.

Keterbatasan ketiga diperhitungkan dalam validasi simulator (RQ1), sedangkan dua keterbatasan pertama dicatat sebagai batas generalisasi hasil.

II.5.3 PPO dan MAPPO

Proximal Policy Optimization (PPO) adalah algoritma RL berbasis kebijakan yang membatasi seberapa jauh kebijakan baru boleh berubah dari kebijakan lama, sehingga pelatihan lebih stabil. Pembatasan ini dilakukan melalui fungsi objektif terpotong (*clipped*) (Ma dkk. 2025):

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta)\hat{A}_t,\ \text{clip}\left(r_t(\theta), 1-\epsilon, 1+\epsilon\right)\hat{A}_t \right) \right] \tag{II.5}$$

dengan $r_t(\theta)$ adalah rasio peluang aksi pada kebijakan baru terhadap kebijakan lama, $\hat{A}_t$ adalah estimasi keunggulan (*advantage*) suatu aksi, dan ϵ adalah batas perubahan. MAPPO memperluas PPO ke banyak agen dengan prinsip pelatihan terpusat dan eksekusi terdesentralisasi. Selama pelatihan, pengkritik (*critic*) dapat melihat informasi global sehingga kebijakan lebih stabil. Saat dijalankan, setiap agen cukup bertindak berdasarkan pengamatannya sendiri (Ma dkk. 2025). Pendekatan ini menjadi salah satu paradigma utama untuk pengambilan keputusan banyak agen dalam kondisi dinamis, dan terbukti unggul atas *baseline* MARL lain pada lingkungan

dengan prioritas tugas yang berubah-ubah (Ma dkk. 2025).

Asumsi. Penerapan MAPPO pada tugas akhir ini mengasumsikan bahwa simulator dapat menyediakan *state* global kepada *critic* selama pelatihan. Asumsi ini wajar karena seluruh lingkungan berada dalam simulasi. Saat evaluasi, kebijakan pertahanan hanya memakai pengamatan agregat yang realistis tersedia bagi protokol. Karena tujuan kedua agen berlawanan, masing-masing agen memiliki kebijakan dan *critic* sendiri, bukan berbagi satu kebijakan seperti pada skenario kooperatif.

Keterbatasan. Ada tiga keterbatasan yang perlu diperhatikan.

1. Bukti keunggulan MAPPO pada Ma dkk. (2025) berasal dari agen-agen yang bekerja sama. Penerapannya pada agen yang saling berlawanan merupakan pilihan rancangan tugas akhir ini, bukan hasil yang sudah terbukti.
2. Pemotongan pada Persamaan (II.5) menstabilkan setiap pembaruan, tetapi tidak menjamin pelatihan konvergen dalam permainan kompetitif, karena kebijakan kedua agen dapat saling berputar tanpa titik henti.
3. PPO tergolong *on-policy*, sehingga membutuhkan banyak episode simulasi. Hal ini berbenturan dengan batas sumber daya komputasi pada Subbab I.4.

Keterbatasan kedua ditangani dengan kumpulan lawan pada Subbab II.5.4, sedangkan keterbatasan ketiga ditangani dengan simulator ringan level *slot* dan *epoch*.

II.5.4 *Self-Play* dan Pelatihan Berbasis Populasi

Pada *self-play*, agen pertahanan dilatih melawan agen penyerang yang juga terus belajar, sehingga keduanya saling mendorong menjadi lebih kuat. Risikonya, agen pertahanan dapat terlalu menyesuaikan diri dengan satu lawan terakhir lalu lemah terhadap strategi lama. Masalah ini diatasi dengan menyimpan kumpulan (*pool*) kebijakan penyerang dari berbagai tahap pelatihan dan mengambil lawan secara acak dari kumpulan tersebut. Wushishi dkk. (2026) menggunakan kumpulan 10 kebijakan penyerang historis yang diambil dengan peluang 0,30 di setiap episode. Hasilnya, pertahanan yang dilatih dengan cara ini hanya mengalami penurunan tingkat mitigasi sekitar 4,9% dari penyerang acak hingga penyerang yang dilatih khusus untuk melawannya. *Population-based training* menerapkan gagasan serupa dengan melatih beberapa varian agen sekaligus agar strategi yang dihasilkan lebih beragam.

Asumsi. Pendekatan ini mengasumsikan bahwa kebijakan penyerang yang tersimpan cukup mewakili ragam strategi yang mungkin dipakai penyerang sungguhan. Dalam tugas akhir ini, ragam tersebut diperluas dengan dua tujuan penyerang, yaitu mencari keuntungan dan mengganggu finalisasi (Subbab II.5.6).

Keterbatasan. Kumpulan lawan selalu terbatas. Karena itu, ukuran *exploitability* hanya menunjukkan kedekatan terhadap penyerang terbaik di dalam kumpulan, bukan terhadap seluruh strategi yang mungkin ada. Wushishi dkk. (2026) sendiri menegaskan bahwa ukuran keseimbangan mereka bersifat relatif terhadap kumpulan, bukan galat keseimbangan Nash yang formal. Studi ablasi mereka juga menunjukkan bahwa keragaman kumpulan tidak berpengaruh signifikan secara tersendiri, meskipun ikut menjaga ketangguhan secara keseluruhan. Untuk mengurangi bias ini, kriteria keberhasilan kedua pada Subbab I.3 mewajibkan pengujian melawan penyerang yang tidak pernah dilihat selama pelatihan.

II.5.5 Metrik Ketangguhan

Ketangguhan pertahanan diukur terhadap penyerang yang terkuat, bukan rata-rata. Dua ukuran yang digunakan adalah sebagai berikut. Pertama, profit relatif penyerang, yaitu selisih pendapatan penyerang dengan pendapatan yang seharusnya ia peroleh jika jujur (Skowroński, 2026):

$$\mathit{Profit}\,(\%) = 100 \times \frac{\mathit{ROI}_{\text{penyerang}} - \mathit{ROI}_{\text{jujur}}}{|\mathit{ROI}_{\text{jujur}}|} \tag{II.6}$$

Nilai positif berarti serangan menguntungkan, sedangkan nilai negatif berarti serangan merugikan penyerang. Kedua, *exploitability*, yaitu seberapa besar penyerang terbaik dalam populasi masih dapat meningkatkan hasilnya terhadap pertahanan yang sudah dibekukan. Semakin kecil nilainya, semakin dekat pasangan kebijakan dengan titik keseimbangan (Wushishi dkk. 2026).

II.5.6 Rancangan Awal Ruang *State*, *Action*, dan *Reward*

Berdasarkan teori dan asumsi di atas, Tabel II.1 menyajikan rancangan awal ruang agen. Rancangan ini menjadi titik awal untuk menjawab RQ1 dan akan dirinci serta divalidasi pada Bab IV. Agen penyerang mengambil keputusan setiap *slot*, karena serangan seperti *reorg* dan *balancing* bergantung pada waktu pelepasan blok dan suara di dalam *slot*. Agen pertahanan mengambil keputusan setiap *epoch*, karena parameter insentif dan finalitas pada Subbab II.2.3 bekerja pada skala *epoch*.

Fungsi *reward* agen pertahanan dirancang sebagai berikut:

$$R_t^d = -\,w_1\,\mathit{Profit}_t \;-\; w_2\,\mathit{Live}_t \;-\; w_3\,\mathit{Safe}_t \;-\; w_4\,\mathit{Cost}_t \;-\; w_5 \sum_j |\phi_{j,t} - \phi_{j,t-1}| \tag{II.7}$$

Tabel II.1 Rancangan awal ruang *state*, *action*, dan *reward* kedua agen

Komponen	**Agen penyerang**	**Agen pertahanan**
Frekuensi keputusan	Setiap *slot*	Setiap *epoch*
State (pengamatan)	Porsi *stake* koalisi; jadwal *proposer* beberapa *slot* ke depan; selisih bobot antarcabang; jumlah blok dan suara yang sedang ditahan; jarak ke *checkpoint* terakhir yang *finalized*; nilai parameter pertahanan saat ini	Tingkat partisipasi *attestation*; jumlah dan kedalaman *reorg* dalam jendela terakhir; jumlah *epoch* sejak finalisasi terakhir; rasio *slot* kosong; rata-rata *reward* validator; jumlah pelanggaran yang terdeteksi; nilai parameter saat ini
Action	Diskret: mengusulkan blok secara jujur, menahan blok, atau melepas blok yang ditahan; memberikan suara tepat waktu, menahan suara, atau melepasnya ke cabang tertentu; mengabaikan *attestation* atau transaksi tertentu (*censorship*)	Diskret: menaikkan, menurunkan, atau mempertahankan satu parameter pada Tabel II.2; satu parameter per keputusan
Reward	Profit relatif (Persamaan (II.6)) untuk varian pencari keuntungan, atau besar keterlambatan finalisasi untuk varian pengganggu	Persamaan (II.7)

dengan keterangan sebagai berikut.

- Profit_t adalah profit relatif penyerang pada *epoch* t.
- Live_t adalah jumlah *epoch* keterlambatan finalisasi di atas toleransi tiga *epoch*. Toleransi ini dipilih karena dalam kondisi normal finalisasi hampir selalu terjadi dalam tiga *epoch* (Laneve & Veschetti, 2025).
- Safe_t bernilai 1 jika terjadi pelanggaran *safety*, misalnya dua *checkpoint* yang saling bertentangan sama-sama final, dan 0 jika tidak.
- Cost_t adalah penurunan relatif *reward* validator jujur dibandingkan parameter bawaan, yaitu biaya pertahanan pada Subbab I.3.
- $\phi_{j,t}$ adalah nilai parameter ke-j pada *epoch* t.
- $w_1, \ldots, w_5$ adalah bobot tiap komponen.

Struktur ini mengikuti Skowroński (2026), yang menggabungkan profit penyerang, gangguan *liveness*, biaya perubahan parameter, dan biaya salah tuduh terhadap pihak jujur dalam satu *reward*. Struktur ini juga sejalan dengan Villegas-Ch dkk. (2025), yang memasukkan latensi, kegagalan validasi, dan pemerataan peran validator ke dalam *reward*. Bobot w_3 ditetapkan paling besar karena pelanggaran *safety* tidak dapat dipulihkan. Suku w_5 mencegah agen mengubah parameter terlalu sering. Nilai bobot akan dipilih melalui pencarian *grid* dan uji sensitivitas, seperti pada Skowroński (2026).

II.5.7 Batas Perubahan Parameter Konsensus

Agar kebijakan pertahanan tidak melanggar spesifikasi dasar protokol, sebagaimana disyaratkan RQ1, parameter dibagi menjadi dua kelompok. Kelompok pertama adalah invarian yang tidak boleh diubah agen, yaitu ambang dua pertiga *stake* pada Persamaan (II.1), durasi *slot* 12 detik, panjang *epoch* 32 *slot*, *stake* minimal 32 ETH, dan aturan *fork-choice*. Ambang dua pertiga dikunci karena menurunkannya akan langsung melemahkan jaminan finalitas ekonomi pada Subbab II.2. Kelompok kedua adalah empat parameter yang boleh disetel, seperti pada Tabel II.2.

Tabel II.2 Rancangan awal parameter yang dapat disetel agen pertahanan beserta batas perubahannya

Parameter	**Nilai acuan**	**Rentang awal**	**Langkah per keputusan**
Pengali *reward* dasar κ_r	1 (Persamaan (II.2))	[0,8; 1,2]	5% dari nilai acuan
Pengali penalti *slashing* κ_s	1, setara 1/32 saldo (Laneve & Veschetti, 2025)	[0,5; 2,0]	5% dari nilai acuan
Batas inklusi *attestation*	32 *slot* (Laneve & Veschetti, 2025)	[16; 32] *slot*	4 *slot*
Pengali laju *inactivity leak* κ_l	1 (Ethereum Foundation, n.d.)	[0,5; 2,0]	5% dari nilai acuan

Selain rentang pada Tabel II.2, setiap keputusan agen pertahanan harus memenuhi batasan berikut:

$$\phi_j^{\min} \le \phi_{j,t} \le \phi_j^{\max}, \qquad |\phi_{j,t} - \phi_{j,t-1}| \le \Delta_j, \qquad \sum_j \mathbf{1}[\phi_{j,t} \neq \phi_{j,t-1}] \le 1, \qquad |\phi_{j,t} - \phi_{j,t-H}| \le \delta_j^{\max} \tag{II.8}$$

dengan $\phi_j^{\min}$ dan $\phi_j^{\max}$ adalah batas rentang, Δ_j adalah langkah maksimum per keputusan, $\mathbf{1}[\cdot]$ bernilai 1 jika kondisinya benar, dan $\delta_j^{\max}$ adalah perubahan kumulatif maksimum dalam jendela H *epoch*. Setiap batasan didasarkan pada temuan berikut.

- Langkah 5% dipilih karena uji sensitivitas Skowroński (2026) menunjukkan bahwa langkah 1% membuat parameter berganti terlalu sering, sedangkan langkah 10–15% membuat parameter melampaui nilai yang tepat.
- Hanya satu parameter yang boleh berubah per keputusan. Pada studi yang sama, mengubah beberapa parameter sekaligus memperlambat pelatihan (347 ribu berbanding 197 ribu langkah) tanpa meningkatkan kinerja.
- Batas perubahan kumulatif meniru pembatasan pergeseran harian pada stu-

di tersebut, yang mencegah agen menggeser parameter sedikit demi sedikit hingga jauh dari nilai aman.

Seluruh batasan ditegakkan melalui *action masking*. Skowroński (2026) melaporkan tidak ada satu pun pelanggaran batas dalam 30 kali uji dengan cara ini, dan Wushishi dkk. (2026) memakai mekanisme serupa untuk menegakkan batas anggaran pertahanan. Villegas-Ch dkk. (2025) juga mencatat bahwa pembatasan perubahan kebijakan penting agar agen tidak menyetel parameter konsensus secara berlebihan. Rentang pada Tabel II.2 merupakan rancangan awal penulis. Rentang final akan dikalibrasi pada Bab IV agar perilaku nominal simulator tetap sesuai dengan data *on-chain*.

II.6 Penerapan AI pada Konsensus *Blockchain*

Rizal dan Kim (2025) mengkaji 120 artikel tentang penerapan AI pada konsensus *blockchain* dan mengelompokkannya menjadi tiga fungsi utama. Fungsi pertama adalah prediksi, misalnya memperkirakan validator berikutnya, biaya transaksi, atau peluang *fork*. Fungsi kedua adalah deteksi anomali dan serangan, misalnya serangan Sybil dan *double spending*. Fungsi ketiga adalah konsensus adaptif yang menyesuaikan parameter terhadap kondisi jaringan, misalnya protokol Sabine yang mengatur jumlah validator PBFT berdasarkan model regresi. Survei tersebut juga mencatat risiko integrasi AI, seperti beban komputasi tambahan, kerentanan terhadap serangan adversarial, dan potensi sentralisasi. Survei ini menempatkan *blockchain* yang mampu menyesuaikan parameternya sendiri secara proaktif sebagai arah riset ke depan, bukan sebagai praktik yang sudah mapan. Risiko sentralisasi yang dicatat survei ini menjadi alasan rancangan pada Subbab II.5.7 hanya mengizinkan perubahan parameter yang berlaku sama bagi semua validator, bukan perlakuan khusus terhadap validator tertentu.

II.7 Pertahanan Adaptif Berbasis *Reinforcement Learning*

Dua penelitian terbaru menunjukkan keunggulan pertahanan yang ikut belajar dibanding pertahanan statis.

Skowroński (2026) meneliti *wave attack* pada *blockchain* PoW, yaitu serangan di mana penambang mengatur naik-turunnya partisipasi untuk mengeksploitasi algoritma penyesuaian kesulitan. Pertahanan statis dengan ambang deteksi tetap awalnya membuat serangan merugi, tetapi penyerang yang menguji batas ambang secara bertahap berhasil kembali untung setelah sekitar 20 hari. Penulis lalu menambahkan agen *Double DQN* yang menyetel ambang deteksi dan masa *cooldown* dalam kerangka CMDP dengan *action masking*. Hasilnya, dalam 30 kali uji, profit penye-

rang tetap negatif ($-42 \pm 13\%$) dibanding $+65 \pm 22\%$ pada pertahanan statis, tanpa satu pun pelanggaran batas keselamatan.

Wushishi dkk. (2026) meneliti penipuan siber (*cyber deception*) pada *Industrial Internet of Things* dengan melatih agen pertahanan DQN secara ko-evolusioner melawan agen penyerang yang ikut belajar dan kumpulan penyerang historis. Pertahanan yang dilatih tanpa penyerang ko-evolusioner tingkat mitigasinya turun dari 0,778 menjadi 0,681 saat menghadapi penyerang adaptif, sedangkan pertahanan ko-evolusioner hanya turun dari 0,836 menjadi 0,803. Studi ablasi juga menunjukkan bahwa memodelkan adaptasi penyerang merupakan komponen paling berpengaruh dalam kerangka tersebut.

Kedua studi ini memberikan pelajaran yang berbeda tetapi saling menguatkan. Skowroński (2026) menunjukkan *apa* yang perlu disetel dan *bagaimana* membatasinya dengan aman, tetapi penyerangnya tidak belajar. Wushishi dkk. (2026) menunjukkan *bagaimana* melatih pertahanan melawan penyerang yang belajar, tetapi di luar domain *blockchain*. Tugas akhir ini mengambil cara pembatasan dari studi pertama dan skema pelatihan dari studi kedua, lalu menerapkannya pada parameter insentif Gasper.

II.8 Penelitian Terkait dan Posisi Tugas Akhir

II.8.1 Studi Primer Terdekat

Dalam cakupan penelusuran, studi primer yang paling dekat dengan tugas akhir ini adalah Villegas-Ch dkk. (2025). Studi tersebut menggabungkan jaringan saraf dalam (*deep neural network*) untuk mengekstraksi ciri jaringan dengan agen DRL (DQN dan PPO). Agen tersebut memilih validator dan menyetel parameter konsensus, yaitu ukuran kuorum, batas waktu propagasi, dan tingkat kesulitan. *Reward*-nya menggabungkan latensi konfirmasi, beban komputasi, pemerataan peran validator, dan tingkat kegagalan validasi. Model dilatih dengan data historis *Ethereum* dan *Hyperledger* yang ditambah skenario serangan Sybil, 51%, dan *denial of service*, lalu diuji pada *testnet Ethereum*, *Hyperledger Fabric*, dan jaringan privat *Hyperledger Besu*. Penulisnya melaporkan latensi konfirmasi rata-rata 320 ms dan ketahanan terhadap serangan hingga 92%.

Studi ini membuktikan bahwa agen RL dapat langsung mengubah parameter konsensus, bukan sekadar mendeteksi ancaman. Namun, ada empat perbedaan penting dengan tugas akhir ini.

1. Serangan berasal dari data dan skenario yang sudah ditetapkan, sehingga pe-

nyerang tidak ikut belajar. Penulisnya sendiri mengakui bahwa model perlu dilatih ulang jika muncul ancaman yang tidak ada dalam data latih.
2. Yang disetel adalah parameter operasional (susunan validator, kuorum, dan tingkat kesulitan), bukan insentif ekonomi (*reward* dan *slashing*).
3. *Reward* tidak memuat profit penyerang, sehingga pertahanan tidak dinilai dari seberapa jauh serangan dibuat merugi.
4. Pengujian tidak dilakukan pada protokol Gasper dengan aturan justifikasi dan finalisasinya.

Selain itu, beberapa angka latensi antara tabel dan narasi dalam studi tersebut tidak konsisten. Karena itu, angka kinerjanya digunakan di sini hanya sebagai gambaran arah, bukan sebagai pembanding kuantitatif.

II.8.2 Perbandingan Penelitian Terkait

Tabel II.3 merangkum perbandingan penelitian terkait, termasuk bagian dari setiap penelitian yang diadopsi oleh tugas akhir ini.

Tabel II.3 Perbandingan penelitian terkait dan bagian yang diadopsi tugas akhir ini

Penelitian	**Objek**	**Penyerang**	**Yang diatur pertahanan**	**Keterbatasan utama**	**Yang diadopsi TA ini**
Laneve & Veschetti (2025)	Gasper	*Scripted*	Tidak ada (tambalan manual)	Penyerang tidak adaptif	Struktur modul simulator dan acuan perilaku normal
Rizal & Kim (2025)	Umum (survei)	–	Prediksi dan deteksi	Konsensus adaptif masih arah riset	Peta pendekatan AI dan risiko sentralisasi
Villegas-Ch dkk. (2025)	*Ethereum*, *Hyperledger*	Skenario dari data	Validator, kuorum, tingkat kesulitan	Penyerang tidak belajar; bukan insentif; bukan Gasper	Bukti agen RL dapat menyetel parameter konsensus; komponen *reward*
Skowroński (2026)	PoW	Adaptif heuristik	Ambang deteksi, *cooldown*	Bukan PoS; penyerang tidak belajar	CMDP, *action masking*, langkah 5%, metrik profit relatif
Wushishi dkk. (2026)	IIoT	Agen RL koevolusioner	Profil pertahanan	Bukan *blockchain*; keseimbangan relatif terhadap kumpulan	Kumpulan penyerang historis; tiga jenis penyerang uji
Ma dkk. (2025)	IIoT	–	Alokasi sumber daya (kooperatif)	Tidak ada lawan	Algoritma MAPPO
Tugas akhir ini	**Gasper**	**Agen MARL**	***Reward*, *slashing*, finalitas**	–	–

II.8.3 Celah Penelitian dalam Cakupan Penelusuran

Berdasarkan Tabel II.3, dan dalam batas cakupan penelusuran pada Subbab II.1, teridentifikasi tiga celah berikut.

1. **Penyerang yang belajar belum diuji pada Gasper.** Analisis Gasper yang ditemukan masih menggunakan penyerang dengan perilaku tetap (Laneve &

Veschetti, 2025). Studi yang sudah menyetel parameter konsensus dengan RL pun masih menghadapi serangan dari skenario tetap (Villegas-Ch dkk. 2025).

2. **Pertahanan adaptif belum menyentuh parameter insentif PoS.** Pertahanan RL yang ditemukan menyetel ambang deteksi (Skowroński, 2026) atau parameter operasional seperti kuorum dan tingkat kesulitan (Villegas-Ch dkk. 2025). Belum ditemukan studi yang menyetel *reward*, *slashing*, dan aturan finalitas dengan batas perubahan yang menjaga spesifikasi protokol.
3. **Pelatihan dua sisi belum diterapkan pada konsensus.** Pelatihan ko-evolusioner terbukti efektif pada domain keamanan lain (Wushishi dkk. 2026), dan MAPPO sudah matang untuk lingkungan multi-agen yang dinamis (Ma dkk. 2025). Namun, dalam literatur yang ditelusuri, keduanya belum digabungkan untuk melatih penyerang dan pertahanan pada protokol konsensus PoS secara bersamaan.

Klaim celah di atas perlu dibaca dengan dua batasan. Pertama, klaim tersebut menyatakan "belum ditemukan dalam cakupan penelusuran", bukan "belum pernah diteliti". Karya yang terbit di prosiding, pracetak, atau jurnal di luar kriteria seleksi, termasuk yang mungkin mengusulkan MARL untuk mendeteksi validator jahat, tidak ikut disintesis. Kedua, bidang ini berkembang cepat, sehingga penelusuran akan diperbarui sebelum laporan akhir disusun.

Dengan batasan tersebut, tugas akhir ini mengisi ketiga celah dengan membangun arena MARL berbasis simulator Gasper. Di dalam arena ini, agen penyerang dan agen pertahanan dilatih bersamaan, dan agen pertahanan menyetel *reward*, *slashing*, serta parameter finalitas dalam batas yang dirancang pada Subbab II.5.7. Celah pertama dijawab melalui RQ3, celah kedua melalui RQ1, dan celah ketiga melalui RQ2. Rincian formulasinya akan dianalisis pada Bab III dan dirancang pada Bab IV.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Menurut **laudon2020<empty citation>**, gambarkan terlebih dahulu model konseptual sistem yang ada saat ini. Model konseptual ini berisi berbagai komponen atau subsitem dan interaksi antarsubsistem tersebut. Setelah itu, berikan penjelasan tentang masalah yang ada pada sistem tersebut. Paragraf berikut berisi contoh penjabaran masalah sistem informasi fasilitas kesehatan untuk pasien (**pressman2019**).

III.2 Analisis Kebutuhan

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

III.2.1 Identifikasi Masalah Pengguna

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

III.2.2 Kebutuhan Fungsional

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie

non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

III.2.3 Kebutuhan Nonfungsional

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetuer at, consectetuer sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

III.3.2 Analisis Penentuan Solusi

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetuer a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetuer. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit

ipsum dolor sed augue. Nulla nec lacus.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before* and *after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.

DAFTAR PUSTAKA

Ethereum Foundation. (n.d.). *Ethereum proof-of-stake attack and defense*. Retrieved October 16, 2026, from https://ethereum.org/developers/docs/consensus-mechanisms/pos/attack-and-defense/

Laneve, C., & Veschetti, A. (2025). A stochastic analysis of the Gasper protocol. *Computer Communications*, *236*, 108123. https://doi.org/10.1016/j.comcom.2025.108123

Ma, Y., Zhao, Y., Hu, Y., He, X., & Feng, S. (2025). Multi-agent deep reinforcement learning for joint task offloading and resource allocation in IIoT with dynamic priorities. *Sensors*, *25*(19), 6160. https://doi.org/10.3390/s25196160

Rizal, S., & Kim, D.-S. (2025). Enhancing blockchain consensus mechanisms: A comprehensive survey on machine learning applications and optimizations. *Blockchain: Research and Applications*, *6*, 100302. https://doi.org/10.1016/j.bcra.2025.100302

Skowroński, R. (2026). Adaptive threat mitigation in PoW blockchains (Part II): A deep reinforcement learning approach to countering evasive adversaries. *Sensors*, *26*(4), 1368. https://doi.org/10.3390/s26041368

Villegas-Ch, W., Govea, J., & Gutierrez, R. (2025). Optimizing consensus in blockchain with deep and reinforcement learning. *Emerging Science Journal*, *9*(4), 1886–1908. https://doi.org/10.28991/ESJ-2025-09-04-08

Wushishi, U., Hussain, N., Hussain, A., Al-Rasheed, A., & Ullah, Z. (2026). Co-ADAM: A co-evolutionary signaling game framework for equilibrium cyber deception in industrial IoT. *Scientific Reports*, *16*, 25306. https://doi.org/10.1038/s41598-026-60920-0

LAMPIRAN A

SOURCE CODE

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

Listing A.1 Binary search code

```
% -- Example of pseudocode and source code listing --
% -- Gunakan minipage agar listing tidak terpotong ke halaman
    berikutnya --



\begin{minipage}{\textwidth}
\begin{lstlisting}[caption={Iterative binary search in Python},
    label={lst:binary_iter}, frame=single, captionpos=t, language=
    Python]
def binary_search(arr, target):
    """
    Performs binary search on a sorted array.

    Args:
        arr: A sorted list of elements
        target: The element to search for

    Returns:
        Index of target if found, -1 otherwise
    """
    left = 0
    right = len(arr) - 1

    while left <= right:
        mid = (left + right) // 2

        if arr[mid] == target:
            return mid
        elif arr[mid] < target:
            left = mid + 1
        else:
```

```
            right = mid - 1

    return -1


\end{lstlisting}
\end{minipage}
```

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas